TÍTULO DE LA ACTIVIDAD

Preparación, entrenamiento y trazabilidad de modelos NLP para CHATBOT CIMA

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	*Actividad 5*
Alumno(a):	*Alfredo Salazar Ruiz*
Matrícula:	*AL03069191*
Docente:	*Luis Ariel Vázquez Piña*
Fecha de entrega:	*18 / 10 / 2026*

Declaración de Uso de Inteligencia Artificial

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	■ Sí ☐ No	Apoyo en el análisis y entregables de la tarea. Mejora de párrafos, ortografía, ideas claras y contexto de este ensayo. asesoría para la Publicación de los contenidos Git Hub. Corrección y mejora de códigos Colab.
Claude (Anthropic)	☐ Sí ■ No	
Gemini (Google)	■ Sí ☐ No	Uso de Gemini para verificar el cumplimiento de la rúbrica.
Copilot (Microsoft)	☐ Sí ■ No	
Otra ():	☐ Sí ■ No	

Desarrollo de Contenido

Instrucciones

1.- Preparación del entorno y repositorio.

- *Crea un repositorio en GitHub con la siguiente estructura mínima:*

```
Actividad5/
├── datos/
│   ├── datos_ini # datos originales
│   └── datos_limp # datos limpios
├── fuentes/
│   ├── entrena.ipynb # notebook de Colab (entrenamiento y evaluación)
│   ├── datos_prep.py # funciones de limpieza
│   └── train.py # script de entrenamiento y registro en MLflow
├── README.md # guía de reproducción y decisiones
└── CHANGELOG.md # reporte final
```

- *Inicializa Git y conéctalo con GitHub.*

2.- Configura MLflow (seguimiento local o remoto) y valida que se registren parámetros, métricas y artefactos.

3.- Genera el repositorio en GitHub.

- *Dataset versionado (o scripts de obtención).*
- *Código en Python (.py) o notebook (.ipynb).*
- *Evidencias de MLflow.*
- *Archivo README.md documentado.*

4.- Reporte técnico en PDF.

- *Debe contener:*
  - *Descripción del dataset (documentar fuente, diccionario de datos y supuestos).*
  - *Proceso de limpieza y estandarización (manejo de valores nulos, tipos de datos, escalado o normalización, codificación de variables categóricas y reglas de negocio).*
  - *Estrategia de versionamiento (registrar cambios en CHANGELOG.md o en el README).*
  - *Visualizaciones relevantes (identificación de patrones y anomalías).*
  - *Descripción de los modelos entrenados.*
  - *Configuración de hiperparámetros.*
  - *Métricas obtenidas (clasificación: accuracy, precision, recall, F1, ROC-AUC; regresión: MAE, RMSE, R^2).*
  - *Comparación estadística de resultados.*
  - *Evidencia del uso de MLflow.*
  - *Reflexión sobre deuda técnica y MLOps.*

5.- Recopila evidencias visuales.

- *Capturas del panel de MLflow.*
- *Tablas o gráficas comparativas de desempeño.*

ENTREGABLES

- *Repositorio en GitHub con los siguientes archivos:*
  a. *Datos: originales y limpios.*
  b. *Programas: funciones de limpieza y script de entrenamiento.*
  c. *README.md.*
  d. *CHANGELOG.md.*
- *Cuaderno (notebook).*
- *Evidencia de registro en MLflow (video o capturas de pantalla).*
- *Reporte técnico en PDF o Word.*

Caso de estudio: Consultor Inteligente de Movimientos a Adjudicados (CIMA)

Repositorio: https://github.com/alfredosalazar-ai/deep-learning-experiments

Alcance: experimento académico con datos sintéticos públicos; sin acceso a pagos reales, sin validación productiva ni autorización automática de operaciones.

Resumen ejecutivo

El problema que motiva este proyecto es de carácter operativo, el cual se enfoca en distinguir consultas sobre un folio de identificación individual de aquellas relacionadas con paquetes, mensajes ambiguos o solicitudes fuera del alcance de CIMA. En una etapa anterior se compararon modelos preentrenados sin ajuste específico al caso, para esta actividad se evaluó un enfoque supervisado y reproducible que combina representación TF-IDF con regresión logística y LinearSVC, el criterio de decisión no es solo obtener una métrica elevada, sino reducir el riesgo de que una consulta no elegible se interprete como individual.

Se partió de 160 solicitudes sintéticas etiquetadas y se eliminaron 32 duplicaciones exactas para trabajar con 128 textos únicos; 102 destinados a entrenamiento y 26 a prueba. Ambos algoritmos se ajustaron mediante GridSearchCV con validación cruzada estratificada de cuatro pliegues.

La regresión logística logró F1 macro de 1.0000 en prueba y 0 falsas elegibilidades, mientras que LinearSVC obtuvo F1 macro de 0.9020 y una falsa elegibilidad. La mejor puntuación de CV también correspondió a regresión logística (0.9186 frente a 0.8492).

Estos resultados respaldan la elección provisional de regresión logística para ampliar la experimentación. No justifican su despliegue, el conjunto es sintético, las clases no están equilibradas después de la depuración y solo existen dos textos AMBIGUA en prueba. La siguiente fase requiere ampliar y etiquetar consultas verdaderamente nuevas, especialmente casos limítrofes.

1.- Contexto y objetivo

CIMA busca orientar consultas vinculadas con movimientos a bienes adjudicados a partir de un folio de asignación. La clasificación de intención es una etapa auxiliar: la elegibilidad real de un pago depende de registros autorizados y reglas deterministas, no de la predicción de un modelo de lenguaje. En consecuencia, clasificar una solicitud no individual como INDIVIDUAL constituye un error de especial atención; no representa por sí mismo la autorización de un pago.

Objetivo: preparar y versionar un dataset público sintético; entrenar y ajustar dos clasificadores; comparar resultados con métricas estandarizadas; documentar hiperparámetros, artefactos y trazabilidad en MLflow; y plantear acciones de MLOps y control humano.

2.- Fuente, variables y supuestos

La fuente de trabajo sigue siendo cima_consultas_cie_sinteticas.csv, construida en la fase anterior. Se inspiró en escenarios y estructuras de Nueva CIE 2.1, pero no contiene movimientos bancarios reales ni el archivo maestro.

Publicar el CSV permite reproducibilidad, pero no lo convierte en una muestra representativa del tráfico operativo.

La principal hipótesis metodológica es que las expresiones textuales aportan información suficiente para una clasificación inicial. No se asume que el clasificador compruebe saldos, estatus de Asignado, relaciones entre folios ni evidencia documental.

Variable	Descripción y uso
id	Identificador del registro; no es una variable predictora.
texto	Consulta sintética en lenguaje natural.
clase_real	Etiqueta objetivo: INDIVIDUAL, PAQUETE, AMBIGUA o FUERA_ALCANCE.
subtipo / dificultad / justificacion	Metadatos descriptivos y trazabilidad; no se incorporan como predictores.
texto_normalizado	Consulta depurada que ingresa al vectorizador TF-IDF.
particion_a5	Separación reproducible entre entrenamiento y prueba.
version_dataset	Versión del conjunto depurado.

3.- Preparación y versionamiento de datos

Se conservó una copia de los 160 registros originales. La limpieza aplicó normalización Unicode NFKC, estandarización de espacios, revisión de campos obligatorios, identificación de registros duplicados por texto y comprobación de etiquetas contradictorias. Se preservaron términos y cifras porque pueden cambiar el significado de la consulta. La versión de entrenamiento se generó sobre textos únicos, sin utilizar la división de desarrollo/evaluación anterior.

Clase	Original	Únicos	Entrenamiento	Prueba
INDIVIDUAL	40	40	32	8
PAQUETE	40	38	30	8
AMBIGUA	40	10	8	2
FUERA_ALCANCE	40	40	32	8
TOTAL	160	128	102	26

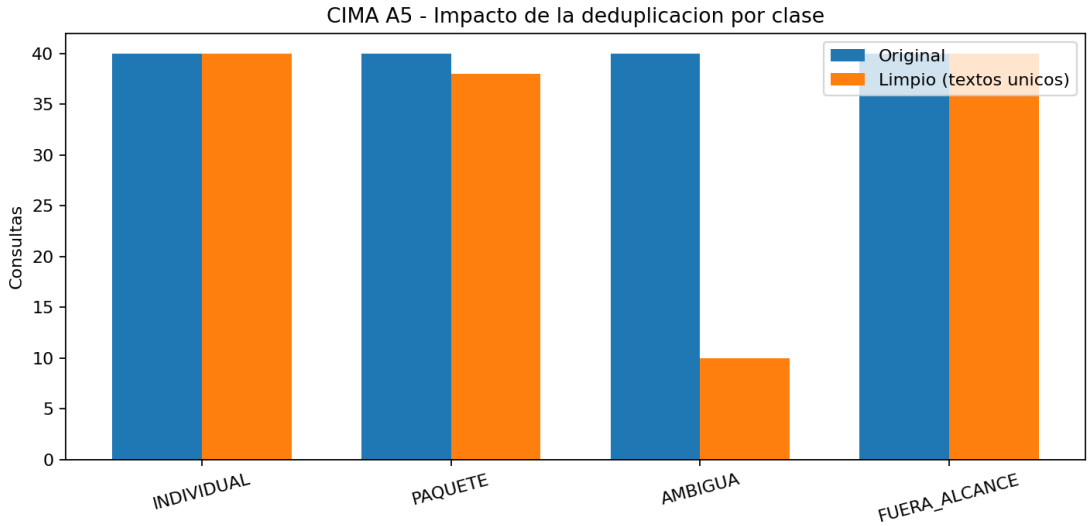


Figura 1. Efecto de la deduplicación sobre el volumen por clase.

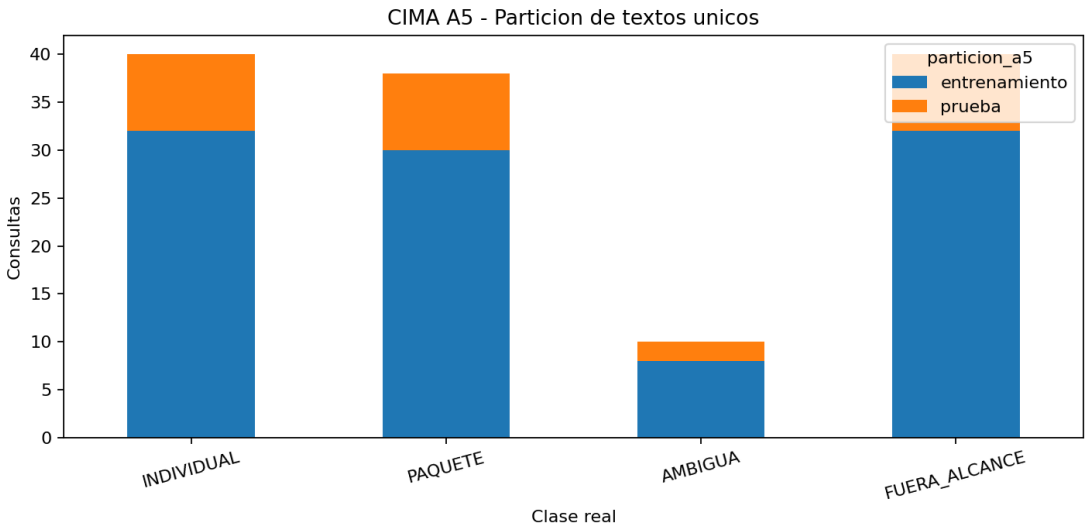


Figura 2. Distribución de entrenamiento y prueba después de la preparación.

El hallazgo principal de calidad de datos es que AMBIGUA disminuye de 40 registros a 10 textos distintos. La caída evidencia repetición de plantillas y reduce la cobertura lingüística. Aunque la partición es estratificada, dos casos de prueba no permiten estimar de manera estable la capacidad de generalización de esa clase. Tampoco se descarta semejanza entre plantillas diferentes.

Se mantiene el Versionamiento ya que el archivo de origen no se sobrescribe, los resultados limpios se guardan en otra carpeta (datos/datos_limp), los cambios de estructura y partición se describen en el CHANGELOG.md y los metadatos de ejecución contienen la huella SHA-256 del archivo limpio y la semilla 20261015.

4.- Modelos y estrategia de búsqueda

Se eligieron dos algoritmos lineales aptos para vectores de texto dispersos. TF-IDF transforma términos y n-gramas en pesos numéricos, mientras que el clasificador aprende la asociación entre patrones y etiquetas. Pipeline integra transformación y estimador para que el vectorizador se ajuste dentro de cada pliegue y evitar fuga de información por vocabulario aprendido sobre validación.

Componente	Configuración
Algoritmos	LogisticRegression y LinearSVC
Validación	StratifiedKFold; k=4; shuffle=True; random_state=20261015
Búsqueda	GridSearchCV; selección por F1 macro; refit=True
Representación	TF-IDF de unigramas o unigramas y bigramas
Espacio de ajuste	tfidf__min_df ∈ {1,2}; clf__C ∈ {0.1,1,10}; clf__class_weight ∈ {None,balanced}
Configuración fija	tfidf__sublinear_tf=True
Prueba final	26 registros reservados, no empleados para seleccionar hiperparámetros

Se prioriza F1 macro porque asigna el mismo peso a cada clase sin dejar que las categorías más frecuentes oculten el bajo desempeño de AMBIGUA. Además se registran accuracy, precision y recall macro, ROC-AUC One-vs-Rest y el indicador operativo de falsa elegibilidad.

5. Resultados y selección de hiperparámetros

Los hiperparámetros seleccionados para regresión logística fueron C=0.1, class_weight=balanced, ngram_range=(1,1) y min_df=1; para LinearSVC, C=1, class_weight=balanced, ngram_range=(1,2) y min_df=1. Ambos utilizaron sublinear_tf=True. La selección se realizó con la puntuación de validación cruzada, antes de medir el conjunto de prueba.

La regresión logística acertó las 26 solicitudes de prueba. LinearSVC registró 25 aciertos y confundió una consulta AMBIGUA con INDIVIDUAL. Dado que 18 solicitudes de prueba no pertenecen a INDIVIDUAL, su tasa de falsa elegibilidad fue 1/18=5.56 %, frente a 0/18 para regresión logística. Este indicador se refiere a la puerta de clasificación, no a un cálculo financiero ni a una validación de pagos.

Indicador	Regresión logística	LinearSVC
Accuracy	1.0000	0.9615
Precision macro	1.0000	0.9722
Recall macro	1.0000	0.8750
F1 macro	1.0000	0.9020
F1 macro CV (mejor)	0.9186	0.8492
Desviación típica CV	0.0487	0.0914
ROC-AUC OvR macro	1.0000	1.0000
Falsas elegibilidades	0 / 18	1 / 18
Tiempo de ajuste	3.77 s	1.22 s
Latencia media/lote por texto	0.0759 ms	0.0629 ms

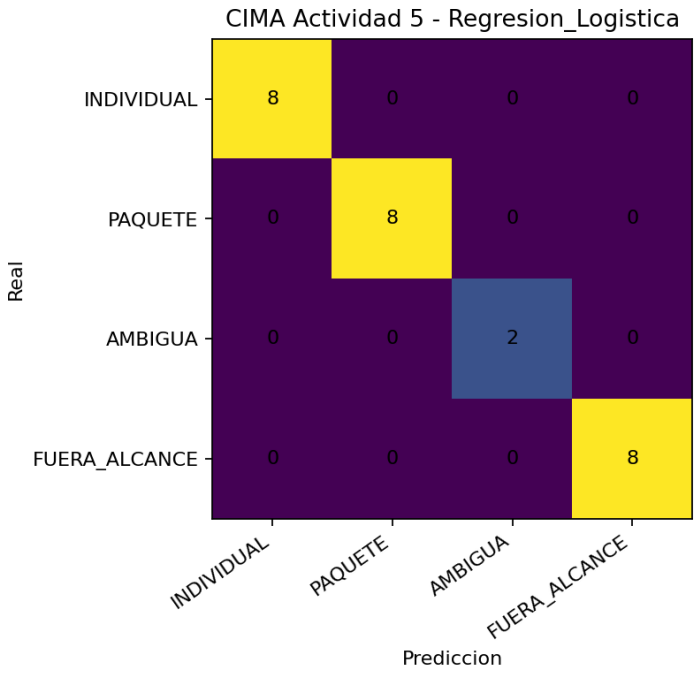


Figura 3. Matriz de confusión de regresión logística en el conjunto de prueba.

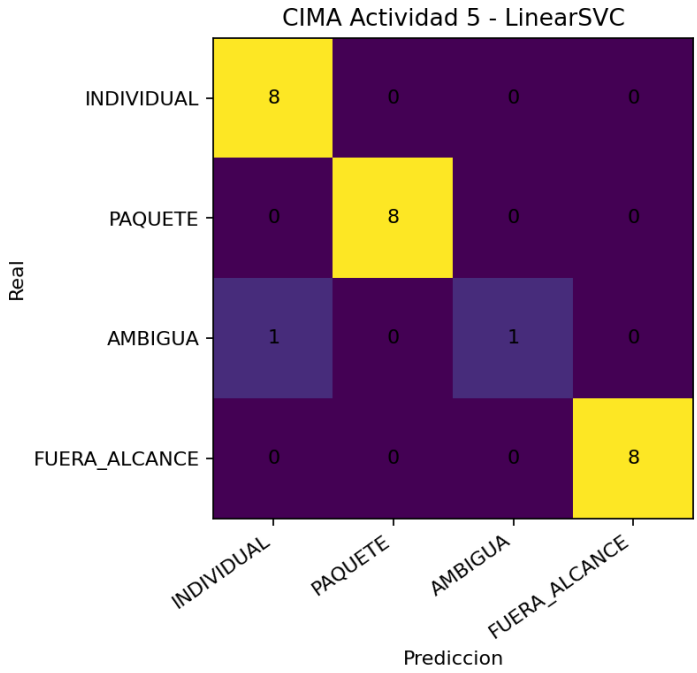


Figura 4. Matriz de confusión de LinearSVC en el conjunto de prueba.

6. Interpretación estadística y límites de inferencia

En prueba, la diferencia observada de F1 macro entre modelos es 0.0980 y la diferencia de accuracy es un acierto de 26 (3.85 puntos porcentuales). En validación cruzada, regresión logística supera a LinearSVC por 0.0694 en F1 macro. Las desviaciones por pliegue (0.0487 y 0.0914) sugieren variación no despreciable, especialmente para LinearSVC. Cuatro pliegues sobre 102 textos no permiten establecer superioridad estadística poblacional mediante esas cifras solamente.

La coincidencia de ROC-AUC=1.0000 en ambos clasificadores no significa igualdad de clasificación. ROC-AUC evalúa el ordenamiento de puntajes y no el acierto de las etiquetas finales; en LinearSVC esos puntajes no son probabilidades calibradas. No procede describirlos como niveles de confianza listos para decidir elegibilidad.

El test sintético es pequeño y está próximo al mecanismo generador de los ejemplos. Por ello, el 100 % observado podría caer sustancialmente ante frases reales, errores ortográficos, combinaciones de solicitudes, cambios operativos o mensajes fuera del diseño. Además, la comparativa con BART, mDeBERTa y XLM-R de la Actividad 4 no es un benchmark controlado: cambian la limpieza, la partición y el modo de entrenamiento.

7.- Trazabilidad mediante MLflow

El entrenamiento registró dos ejecuciones finalizadas en el experimento CIMA_Actividad5_NLP_Supervisado. MLflow almacenó los parámetros óptimos, las métricas de prueba y CV, la huella del dataset, la semilla, la cantidad de registros, el identificador de cada ejecución y artefactos de búsqueda, reportes y matrices. El backend de seguimiento se configuró con SQLite (mlflow.db) porque la versión instalada restringía el uso directo de FileStore.

Modelo	Run ID MLflow	Estado
Regresión logística	0edae5f0a1414a00b4515a080455f215	FINISHED
LinearSVC	fc6330fcfdf74862ace130a6ee90fc14	FINISHED

Se exportaron dos paquetes de modelo nativo MLflow, cada uno con archivo MLmodel, formato model.skops y definiciones de entorno. También se conservaron dos modelos joblib para análisis local. La evidencia demuestra registro y exportación, pero no una prueba independiente de carga y ejecución en una segunda infraestructura. La base SQLite y la carpeta de artefactos deben conservarse conjuntamente; las URI absolutas de Colab requieren atención si se restaura en otro entorno.

Las evidencias de seguimiento "base SQLite mlflow.db" fueron restaurados en las rutas originales de Colab, modelos nativos exportados y capturas del panel MLflow 3.17.1. La restauración permite consultar nuevamente los archivos asociados a los mismos identificadores de ejecución, sin reentrenar ni modificar las métricas.

8.- Deuda técnica, MLOps y control operativo

El primer riesgo es la calidad de los datos: un conjunto creado con patrones controlados puede premiar la memorización y dejar fuera maneras reales de formular consultas. La prioridad es generar más ejemplos independientes de AMBIGUA y FUERA_ALCANCE, implementar un protocolo de etiquetado por dos revisores y mantener una prueba congelada con textos posteriores a la capacitación.

El segundo riesgo es operativo: CIMA nunca debe interpretar la etiqueta INDIVIDUAL como validación de un movimiento financiero. El modelo solamente propone una ruta de consulta. Antes de recuperar o responder importes deben verificarse el folio individual, el estado Asignado, el tipo de pago y la fuente maestra autorizada. Las solicitudes de paquete y las ambiguas se escalan a revisión humana cuando no existe evidencia suficiente.

El tercer riesgo es de mantenimiento: cambios en vocabulario, canales o estructuras de la CIE podrían reducir el desempeño. Una estrategia MLOps mínima debe versionar datos y código, registrar hashes y modelos, validar el esquema al publicar, monitorear distribución de clases y falsas elegibilidades, revisar errores humanos y permitir volver a una versión conocida. También se debe limitar el acceso y evitar registrar texto operativo sensible en experimentos públicos.

Como siguiente iteración conviene aplicar un umbral de decisión o regla de abstención evaluada con datos independientes, realizar pruebas de estrés con expresiones nuevas y valorar si un modelo lineal con menor costo computacional mantiene desempeño suficiente frente a alternativas más complejas. No se recomendará una automatización financiera hasta disponer de pruebas fuera de muestra y controles humanos verificables.

9.- Conclusión y decisión

La preparación de los datos fue tan determinante como el algoritmo. Eliminar 32 repeticiones mejoró la claridad del entrenamiento, pero también puso en evidencia que la categoría AMBIGUA carece de diversidad. Esta observación explica por qué no basta con informar un 100 % de accuracy sin revisar la muestra sobre la cual se obtuvo.

Selecciono regresión logística como modelo candidato para una fase adicional de validación, porque mostró mejor F1 macro en la búsqueda, mayor estabilidad entre pliegues y ninguna falsa elegibilidad en la prueba reservada. LinearSVC fue más rápido, pero cometió el único error de enrutamiento de mayor interés operativo. Mi decisión no es incorporar inmediatamente el modelo a producción, sino ampliar los datos, evaluar nuevas frases y conservar la trazabilidad de cada cambio mediante MLflow. En CIMA, el aprendizaje automático debe complementar las reglas y la supervisión humana, no sustituirlas.

Referencias Bibliográficas

Universidad Tecmilenio. (2026). Gestión de proyectos de inteligencia artificial [Curso en línea].
https://cursos.tecmilenio.mx/courses/252871

Google. (s. f.). Gemini: Tu asistente de IA de Google.
https://gemini.google/mx/about/

OpenAI. (s. f.). ChatGPT.
https://chatgpt.com/es-419/

CIMA. (2026). Dataset sintético, scripts y resultados de la Actividad 5.
https://github.com/alfredosalazar-ai/deep-learning-experiments

scikit-learn. (s. f.). GridSearchCV.
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

scikit-learn. (s. f.). Pipeline.
https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html

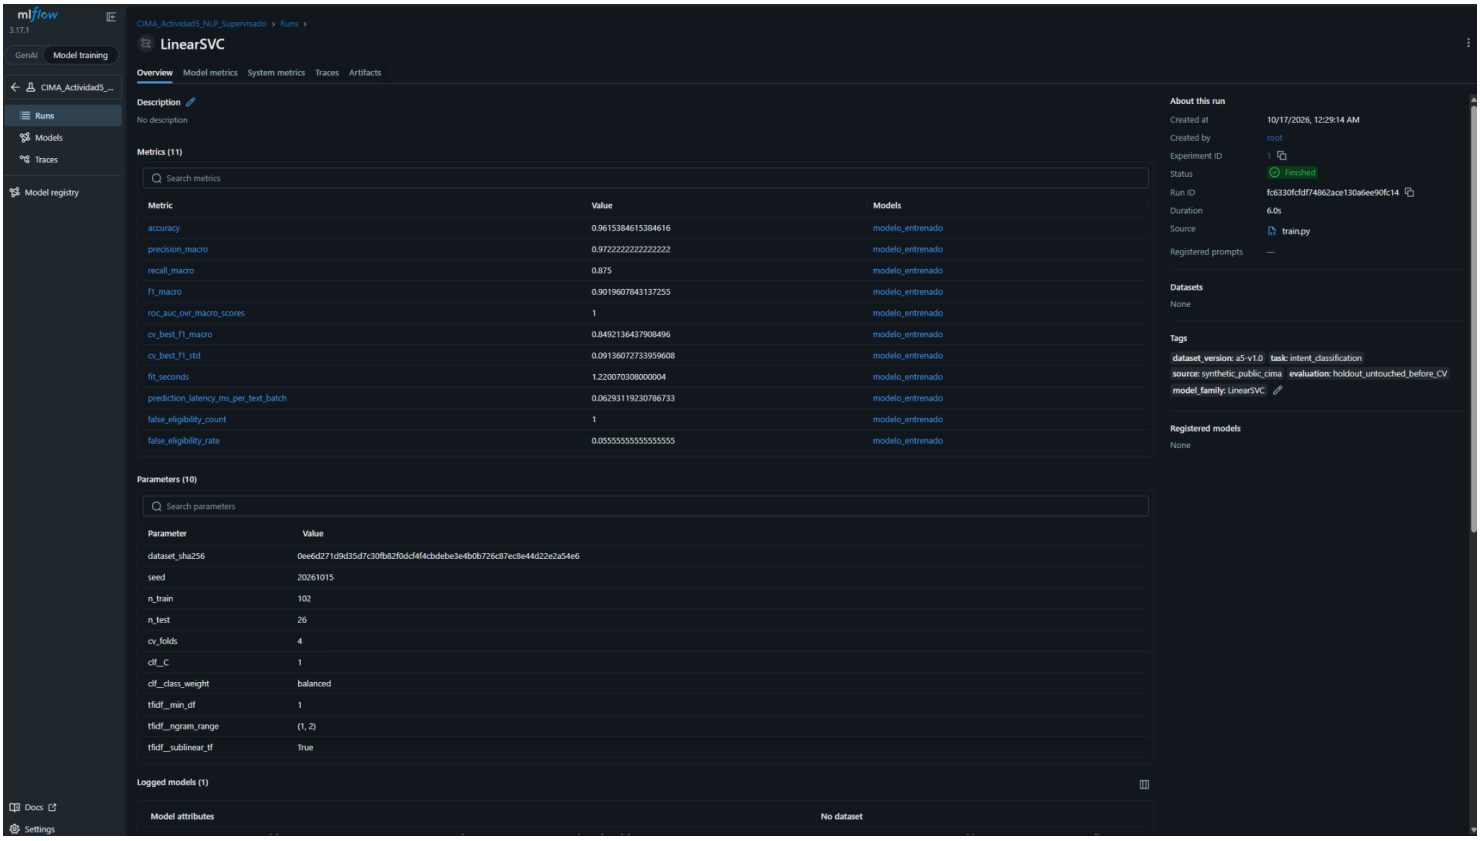
MLflow. (s. f.). MLflow Tracking.
https://mlflow.org/docs/latest/ml/tracking/

Nota: las métricas, matrices y parámetros de este informe se extrajeron de los archivos de salida proporcionados. No se realizó un nuevo entrenamiento ni se infieren resultados externos.

Anexo A. Evidencias de MLflow

Las siguientes capturas documentan la visualización de las ejecuciones originales en MLflow 3.17.1, utilizando la base SQLite recuperada y los artefactos restaurados en el entorno temporal de Google Colab. Se conservaron los mismos identificadores de ejecución; no se realizaron nuevos entrenamientos para obtener estas evidencias.
Regresión logística registró accuracy y F1 macro de 1.0000, mientras que LinearSVC obtuvo accuracy de 0.9615 y F1 macro de 0.9020. Estos resultados corresponden a 26 consultas sintéticas de prueba y no demuestran desempeño productivo.

A1. LinearSVC — parámetros, métricas y estado de la ejecución



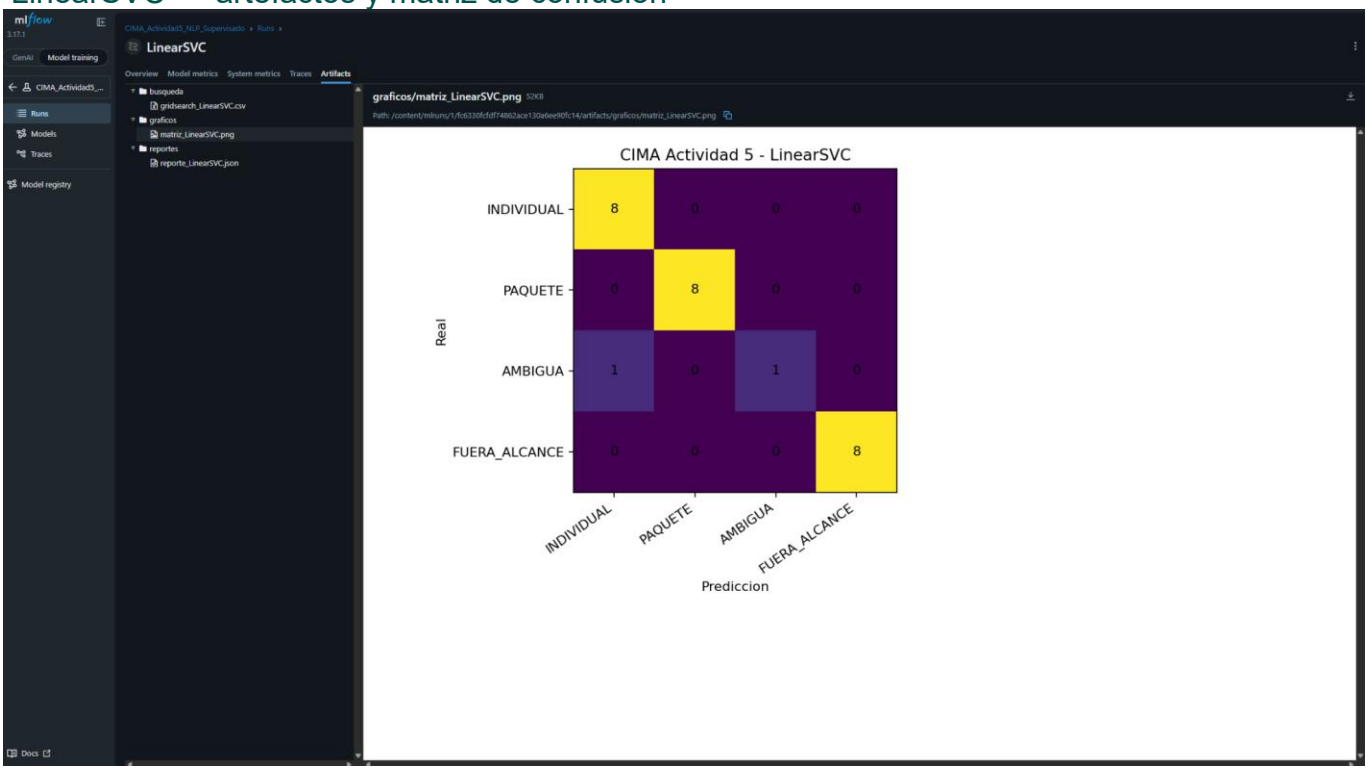
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A2. LinearSVC — visualización de métricas en MLflow



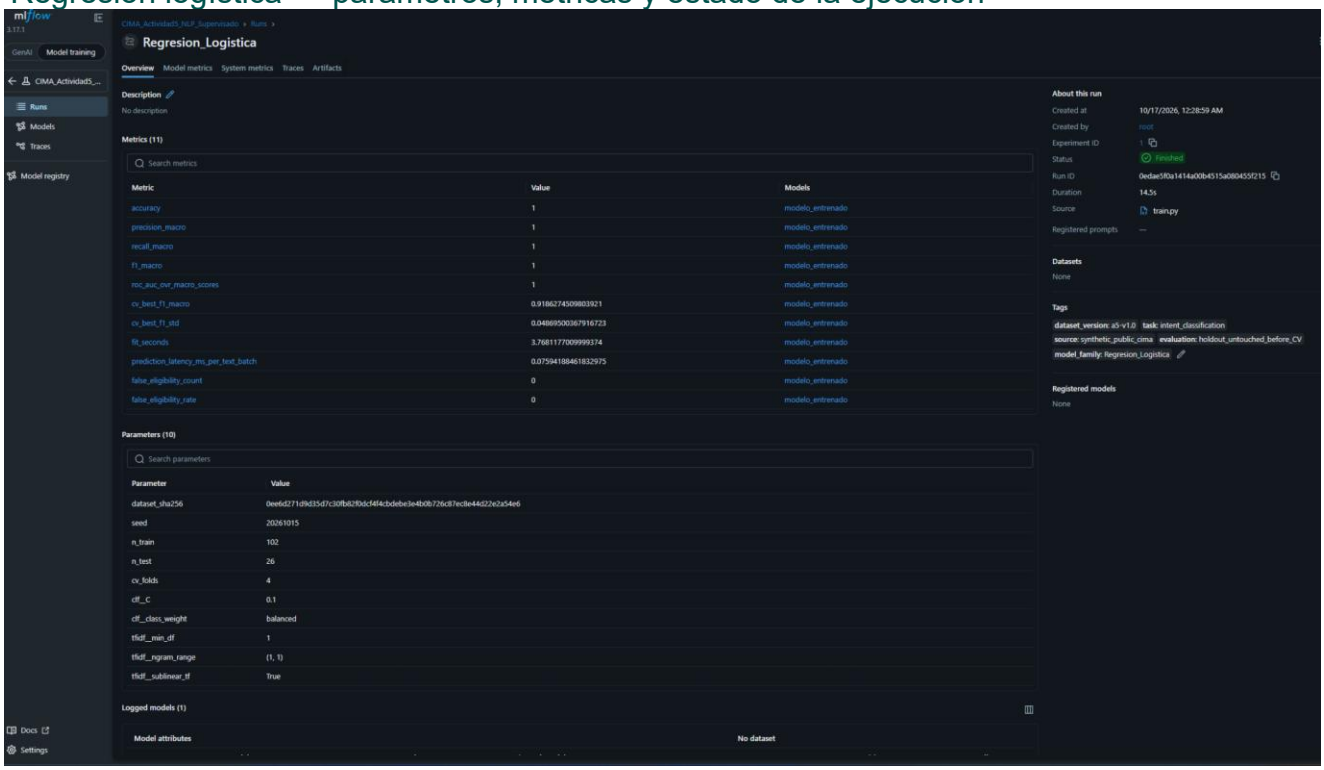
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

3. LinearSVC — artefactos y matriz de confusión



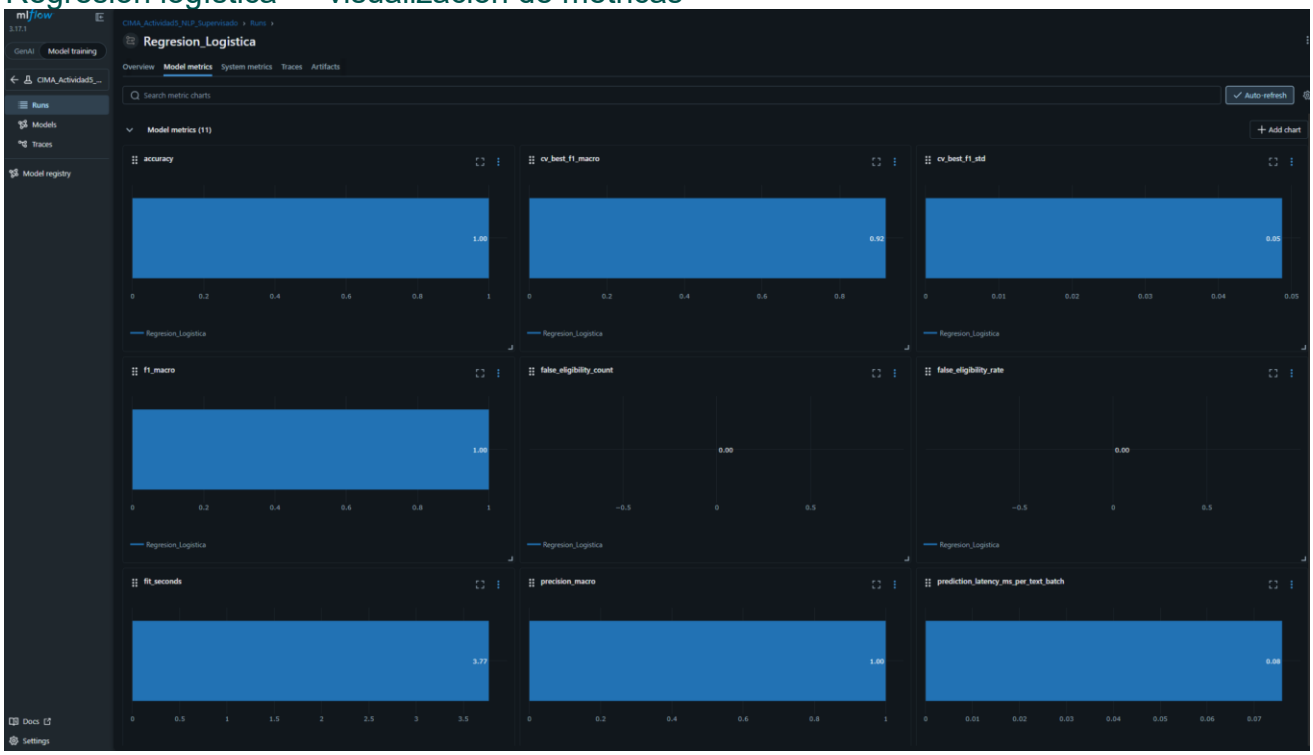
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A4. Regresión logística — parámetros, métricas y estado de la ejecución



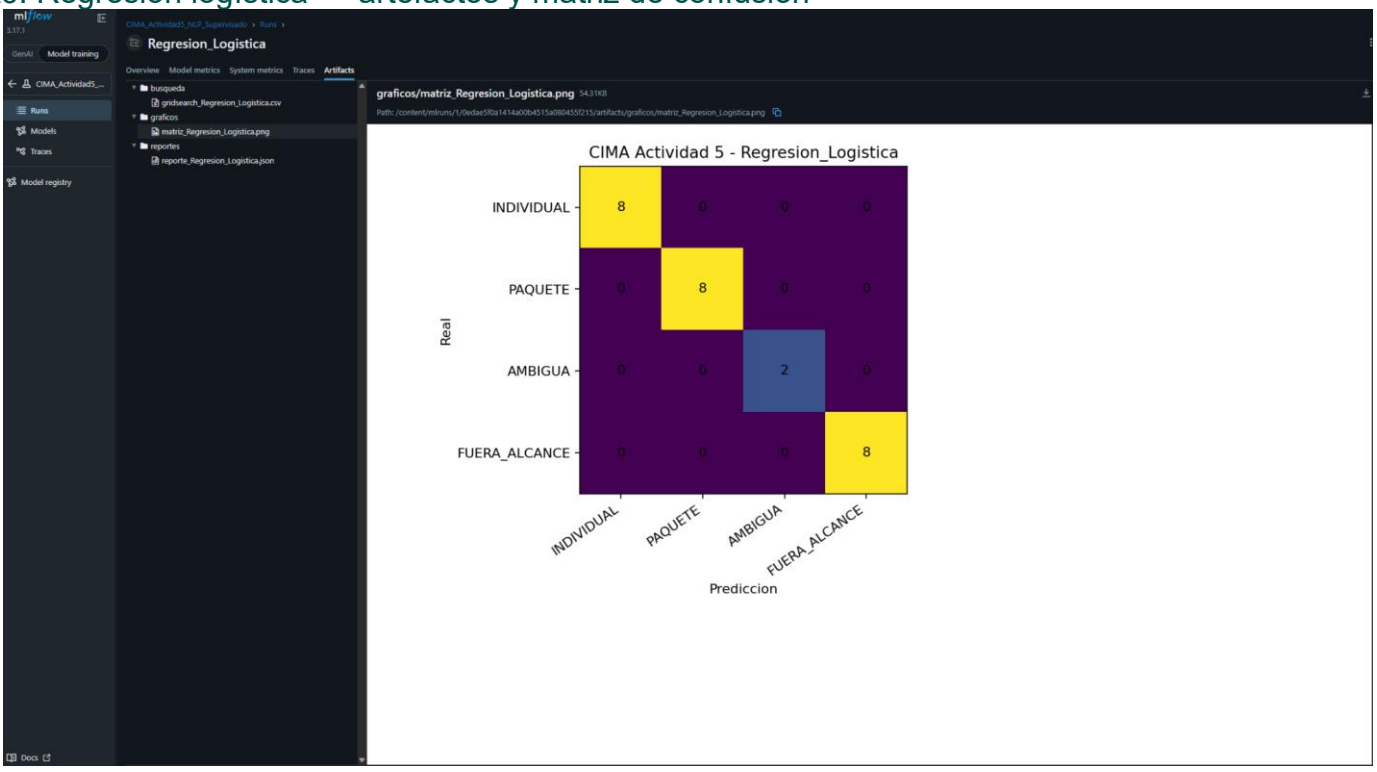
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A5. Regresión logística — visualización de métricas



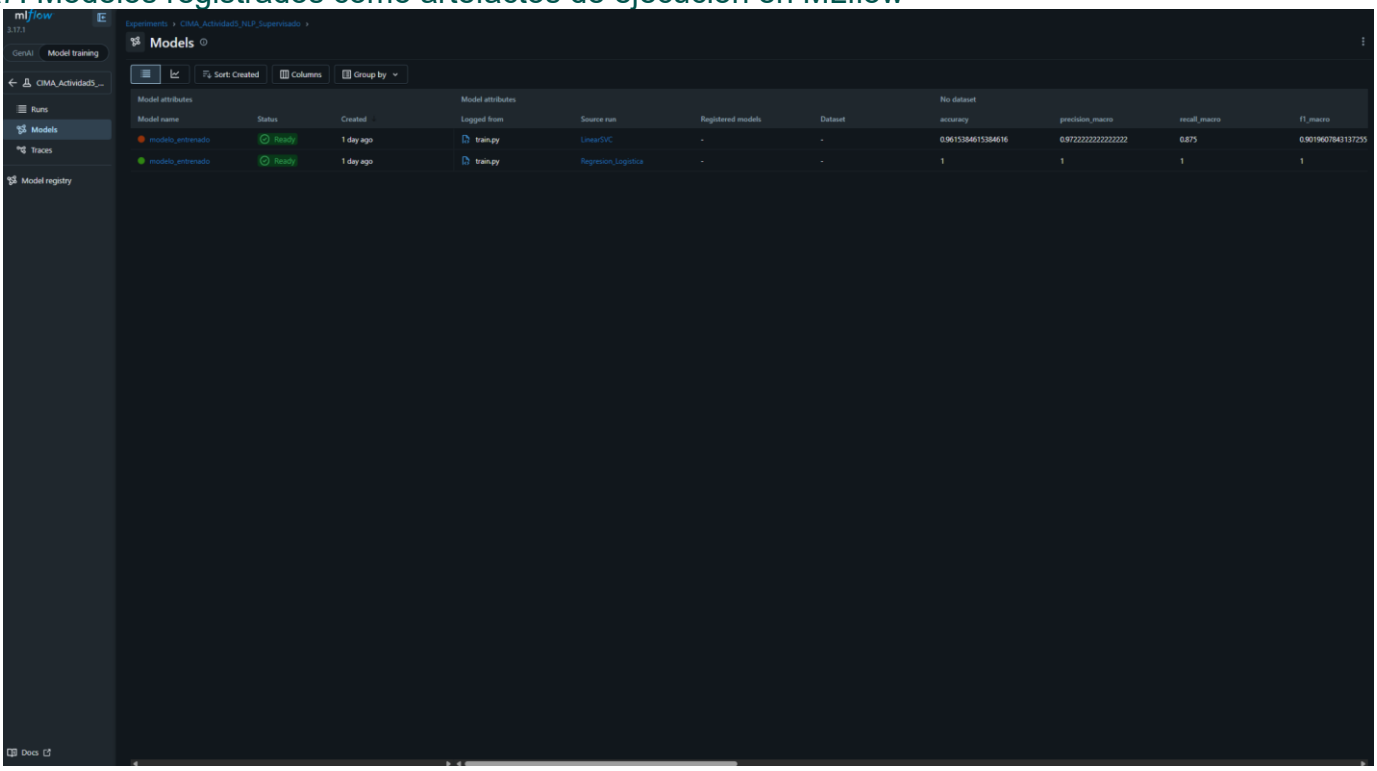
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A6. Regresión logística — artefactos y matriz de confusión



Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A7. Modelos registrados como artefactos de ejecución en MLflow



Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.