Evaluación y validación de modelos de clasificación para CHATBOT CIMA

Métricas, umbrales, comparación estadística y decisión operativa

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	*Actividad 6*
Alumno(a):	*Alfredo Salazar Ruiz*
Matrícula:	*AL03069191*
Docente:	*Luis Ariel Vázquez Piña*
Fecha de entrega:	*25 / 10 / 2026*

Declaración de Uso de Inteligencia Artificial

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	■ Sí ☐ No	Apoyo en el análisis y entregables de la tarea. Mejora de párrafos, ortografía, ideas claras y contexto de este ensayo. asesoría para la Publicación de los contenidos Git Hub. Corrección y mejora de códigos Colab.
Claude (Anthropic)	☐ Sí ■ No	
Gemini (Google)	■ Sí ☐ No	Uso de Gemini para verificar el cumplimiento de la rúbrica.
Copilot (Microsoft)	☐ Sí ■ No	
Otra ():	☐ Sí ■ No	

Desarrollo de Contenido

Instrucciones

Deberás seleccionar un problema de clasificación (clínico, financiero o social) y establecer un objetivo SMART para evaluar el desempeño de un modelo de aprendizaje automático. La actividad debe cumplir con los siguientes elementos:

1.- Reporte técnico de evaluación y validación del modelo.

- *Extensión sugerida: 6 a 8 páginas*
- *Contenido:*
  - *Definición del problema y contexto.*
  - *Matriz de confusión e interpretación.*
  - *Cálculo e interpretación de métricas.*
  - *Ajuste de umbral.*
  - *Interpretación de la curva ROC y AUC.*
  - *Resultados de validación cruzada.*
  - *Comparación con baseline.*
  - *Análisis de pruebas A/B.*
  - *Justificación técnica y su relación con el impacto en el negocio.*
  - *Conclusiones.*

2.- Notebook o script de experimentación.

- *Contenido:*
  - *Código del modelo.*
  - *Cálculo de métricas.*
  - *Validación cruzada.*
  - *Ajuste de umbral.*
  - *Implementación de pruebas A/B.*
  - *Evidencia de experimentos.*

3.- Tablero visual de resultados.

- *Contenido:*
  - *Código del modelo.*
  - *Cálculo de métricas.*
  - *Validación cruzada.*
  - *Ajuste de umbral.*
  - *Implementación de pruebas A/B.*
  - *Evidencia de experimentos.*

ENTREGABLES

Debes entregar un archivo en formato ZIP que contenga:
Repositorio en GitHub con los siguientes archivos:

1. *Un reporte técnico de evaluación y validación del modelo en formato PDF o Word.*
2. *Un notebook o script de experimentación en formato Python (.ipynb o .py).*
3. *Un tablero visual de resultados en formato Trello (capturas en PDF o enlace).*

Caso aplicado: Consultor Inteligente de Movimientos a Adjudicados (CIMA)

Repositorio:

https://github.com/alfredosalazar-ai/deep-learning-experiments/Actividad6

Alcance: Evaluación y validación complementaria de los clasificadores de la Actividad 5.

El análisis incluye matrices de confusión, métricas por clase, ROC/AUC, baseline, validación cruzada, umbral de decisión, comparación estadística pareada y simulación offline de políticas A/B.

Resumen ejecutivo

En esta actividad se evalúa si dos clasificadores supervisados pueden distinguir consultas operativas de CIMA en cuatro clases: INDIVIDUAL, PAQUETE, AMBIGUA y FUERA_ALCANCE. El análisis retoma los modelos entrenados en la Actividad 5 y aplica métricas, un baseline, evaluación de umbral y comparación estadística sobre la prueba reservada.

En los 26 registros de prueba, Regresión Logística obtuvo accuracy, precision macro, recall macro y F1 macro de 1.0000. LinearSVC obtuvo accuracy de 0.9615 y F1 macro de 0.9020, con una confusión de AMBIGUA como INDIVIDUAL. El baseline mayoritario alcanzó accuracy de 0.3077 y F1 macro de 0.1176. El resultado favorece a Regresión Logística en esta muestra, pero no acredita desempeño productivo.

1.- Problema y objetivo de evaluación

En CIMA, una consulta clasificada como INDIVIDUAL puede continuar hacia un flujo de consulta de movimientos, una solicitud ambigua o relacionada con varios folios debe aclararse o escalarse. El error más sensible es una falsa elegibilidad: clasificar como INDIVIDUAL un caso que no pertenece a esa clase. La etiqueta no autoriza un pago ni confirma una asignación financiera, esas comprobaciones dependen de fuentes maestras autorizadas y reglas deterministas.

Objetivo SMART

Comparar Regresión Logística y LinearSVC sobre las 26 consultas de prueba y evaluar una política de aceptación selectiva que busque cero falsas aceptaciones observadas, cuantificando la cobertura automática y la carga de revisión. La meta es experimental, no una garantía de riesgo cero en producción.

Alcance

Evaluación retrospectiva sobre datos sintéticos, no hay tráfico productivo ni asignación aleatoria de usuarios.

La prueba contiene 8 INDIVIDUAL, 8 PAQUETE, 2 AMBIGUA y 8 FUERA_ALCANCE.

Las conclusiones se limitan a esta muestra y requieren consultas independientes.

2.- Dataset, preparación y estrategia metodológica

Se utilizó la versión limpia de 128 textos únicos derivada del dataset sintético de la Actividad 5. La copia histórica conserva 160 registros, la deduplicación exacta retiró 32 repeticiones. Se reservaron 102 registros para entrenamiento y 26 para prueba. Se mantiene la partición de referencia.

Clase	Únicos	Entrenamiento	Prueba
INDIVIDUAL	40	32	8
PAQUETE	38	30	8
AMBIGUA	10	8	2
FUERA_ALCANCE	40	32	8
Total	128	102	26

La debilidad de datos más importante es AMBIGUA: quedaron 10 textos únicos tras deduplicar y solo 2 en prueba. Una sola predicción cambia sustancialmente sus métricas por clase. La cobertura lingüística es limitada y el origen sintético puede hacer que expresiones de prueba sean parecidas a las de entrenamiento.

Modelos y métodos

Los dos pipelines combinan TF-IDF con clasificadores lineales. Regresión Logística ofrece probabilidades estimadas, LinearSVC produce márgenes de decisión, que no son probabilidades calibradas. Se calcularon accuracy, precision, recall y F1 macro, ROC-AUC, falsas elegibilidades y latencia observada.

Componente	Aplicación en la evaluación
Prueba final	26 registros reservados, no se utilizan para seleccionar umbrales.
Baseline	DummyClassifier de clase mayoritaria del entrenamiento.
Umbral	Seleccionado con puntuaciones out-of-fold (OOF) de entrenamiento.
ROC/AUC	INDIVIDUAL frente a NO_INDIVIDUAL, además del AUC multiclase reportado.
Significancia	Prueba exacta de McNemar sobre predicciones emparejadas.
A/B	Simulación retrospectiva entre políticas, no experimento real.

3.- Resultados iniciales y matrices de confusión

Métrica	Regresión logística	LinearSVC	Baseline
Accuracy	1.0000	0.9615	0.3077
Precision macro	1.0000	0.9722	0.0769
Recall macro	1.0000	0.8750	0.2500
F1 macro	1.0000	0.9020	0.1176
ROC-AUC OvR macro	1.0000	1.0000	No calculado
Falsas elegibilidades	0	1	0
Latencia por texto (ms)	0.7754	0.1074	N/A

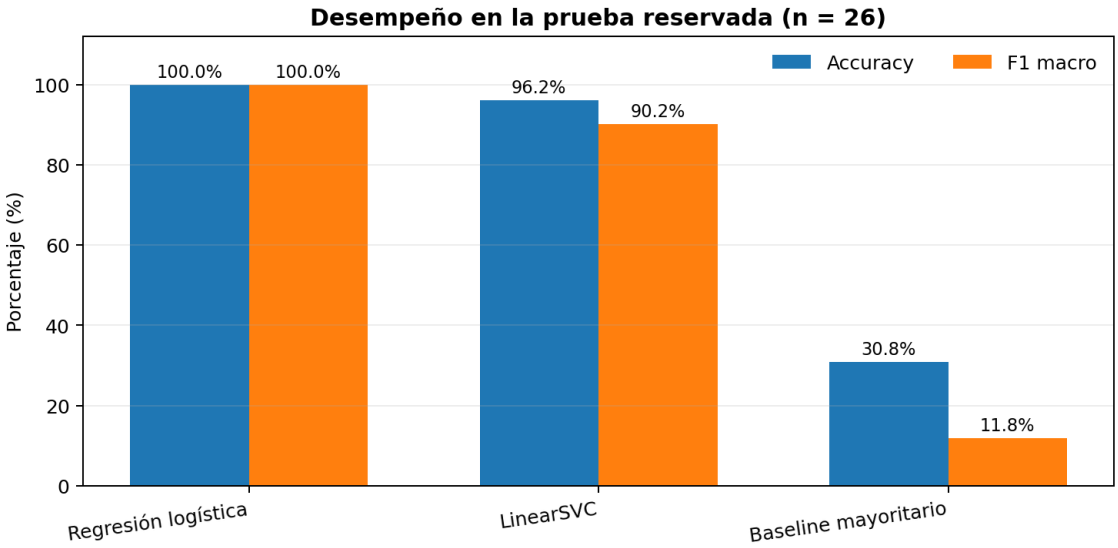


Figura 1. Accuracy y F1 macro sobre los mismos 26 registros de prueba.

Regresión Logística acertó los 26 casos. LinearSVC cometió un error: una consulta AMBIGUA se clasificó como INDIVIDUAL. El baseline mayoritario es una referencia simple, no una política operativa. La latencia observada en una medición preliminar de Colab depende del entorno, la carga y el hardware, no se utiliza para seleccionar el modelo ni se incluye en la tabla de métricas consolidadas, y tampoco equivale a un SLA.

4. Matrices de confusión y ROC/AUC

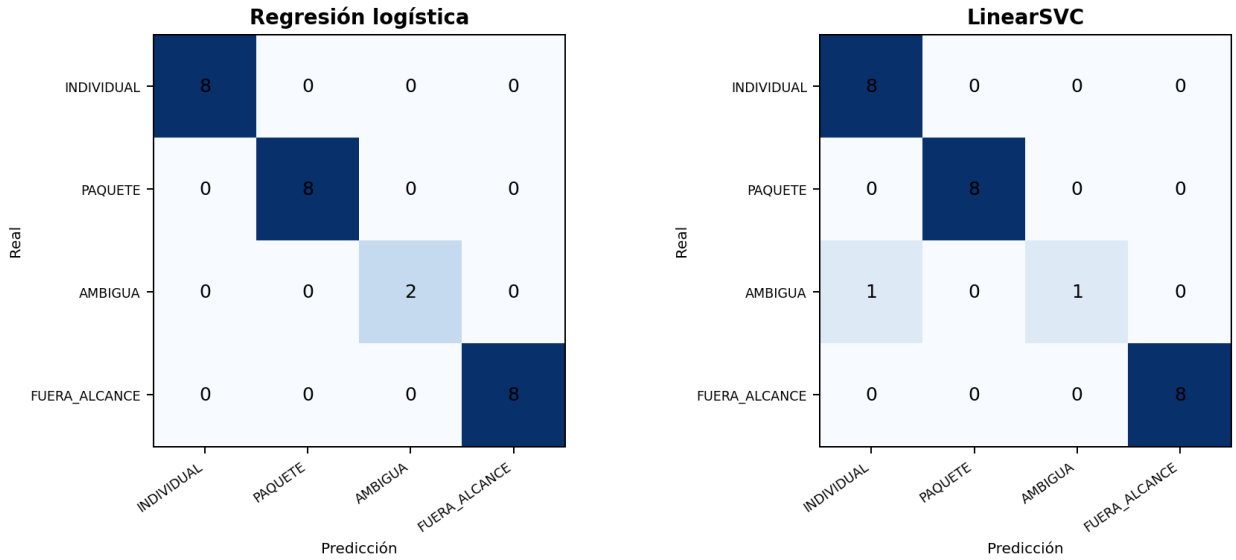


Figura 2. Matrices de confusión comparadas: el único error de LinearSVC fue AMBIGUA → INDIVIDUAL.

La matriz explicita el tipo de error detrás del score agregado. Para CIMA, una solicitud sin información suficiente no debe avanzar automáticamente como consulta individual. La respuesta debe estar separada de la validación del folio, del estado de asignación y del tipo de pago.

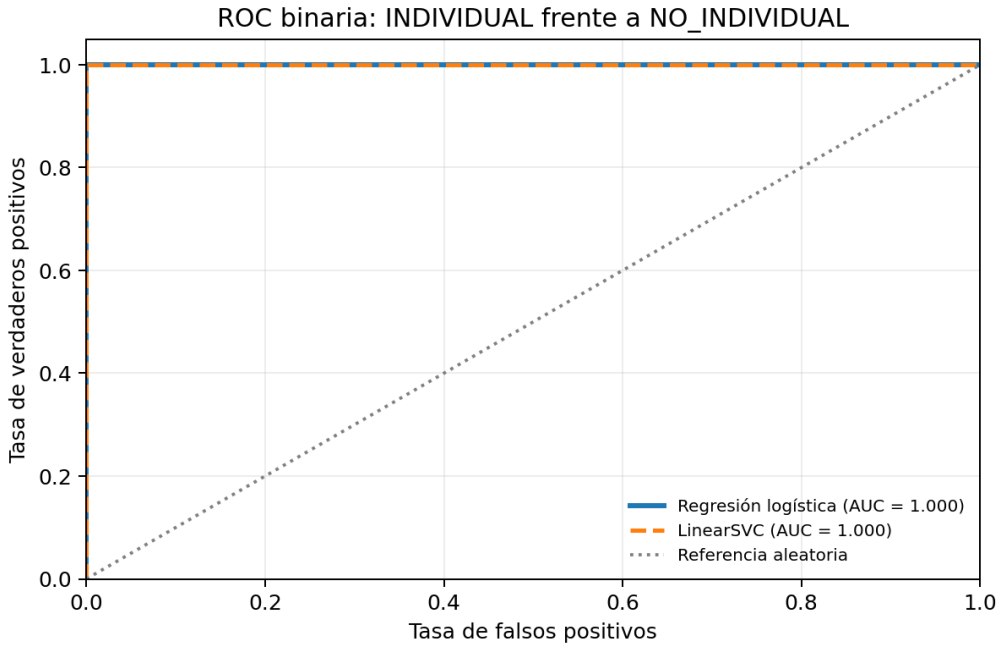


Figura 3. ROC binaria para INDIVIDUAL frente a NO_INDIVIDUAL, a partir de AUC=1.000 reportado en la prueba.

El AUC reportado es 1.0000 para ambos modelos en 26 casos. Implica una ordenación perfecta de los puntajes en esta muestra, no la garantía de que el comportamiento se repetirá fuera de ella. La curva es una estimación empírica de una muestra pequeña, con nuevos casos la forma y el AUC pueden cambiar. El margen de LinearSVC no es una probabilidad calibrada.

5.- Ajuste de umbral y política de abstención

El umbral se seleccionó con puntuaciones out-of-fold (OOF) generadas en cuatro pliegues sobre los 102 registros de entrenamiento. Entre los casos que el clasificador multiclase predijo como INDIVIDUAL, se eligió el umbral que maximiza los verdaderos positivos sujeto a cero falsas elegibilidades OOF, en caso de empate se conserva el umbral más alto. La prueba reservada no intervino en esa selección. La política acepta INDIVIDUAL solo si se mantiene esa predicción de clase y el puntaje supera el umbral, los demás casos se derivan a REVISION_HUMANA.

Indicador	Regresión logística	LinearSVC
Puntaje	Probabilidad estimada	Margen vs. resto
Umbral	0.276334	0.949838
Falsas aceptaciones OOF	0	0
INDIVIDUAL aceptados	8/8	8/8
Falsas aceptaciones en prueba	0	0
Enviados a revisión	18/26	18/26
Cobertura automática	30.77 %	30.77 %

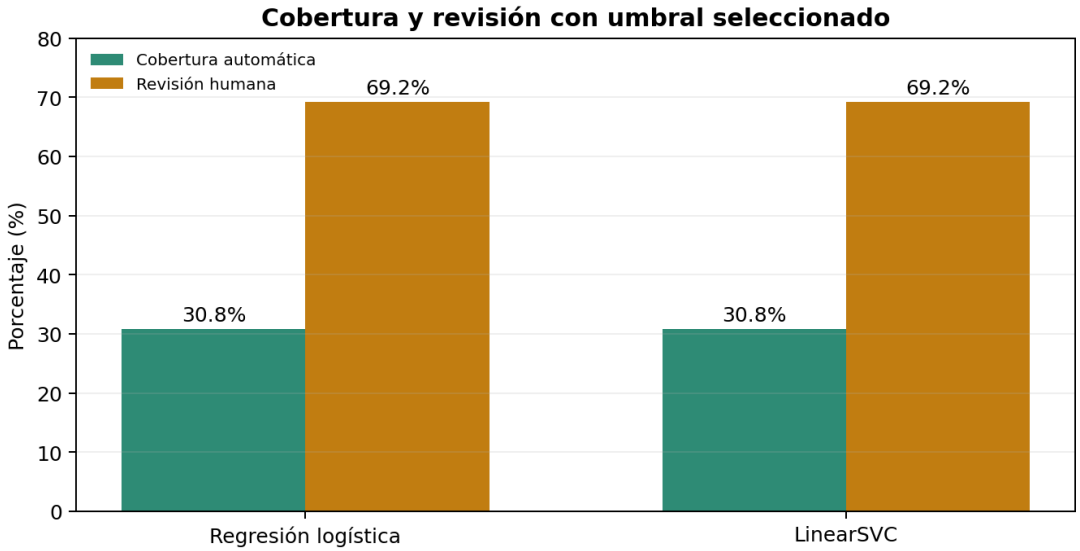


Figura 4. La política acepta ocho casos y deriva dieciocho a revisión en ambos modelos.

Con los umbrales de la ejecución consolidada (0.276334 para Regresión Logística y 0.949838 para LinearSVC), la política aceptó las ocho consultas INDIVIDUAL y derivó 18 de 26 casos a revisión (69.23 %). No se observaron falsas aceptaciones en esta muestra, pero no se puede afirmar que el riesgo sea cero fuera de ella. Los umbrales pertenecen a escalas distintas: el primero es una probabilidad estimada y el segundo un margen de decisión, por lo que no deben compararse como probabilidades equivalentes.

6. Validación cruzada, significancia y simulación A/B

La ejecución consolidada volvió a evaluar las configuraciones congeladas de la Actividad 5 mediante validación cruzada estratificada de cuatro pliegues sobre los 102 registros de entrenamiento, no se realizó una nueva búsqueda GridSearch. Regresión Logística obtuvo F1 macro por pliegue de 1.0000, 0.8706, 0.9020 y 0.9020 (media 0.9186, desviación estándar poblacional 0.0487). LinearSVC obtuvo 0.9020, 0.6910, 0.9020 y 0.9020 (media 0.8492, desviación estándar poblacional 0.0914). Estos resultados evalúan las configuraciones fijadas, no sustituyen una prueba con consultas nuevas e independientes.

Comparación	Discordancias	p exacta McNemar	Interpretación
Regresión logística vs. LinearSVC	1 vs. 0	1.000000	No significativa
Regresión logística vs. baseline	18 vs. 0	0.000008	Significativa en la muestra
LinearSVC vs. baseline	17 vs. 0	0.000015	Significativa en la muestra
Política A (revisión total) vs. política B (umbral)	0 vs. 8	0.007813	Diferencia observada en esta muestra, simulación retrospectiva, no A/B causal.

La prueba exacta de McNemar contrasta errores emparejados. No se observó una diferencia estadísticamente significativa entre los dos modelos entrenados (p=1.0000), dado que solo existe un caso discordante. Frente al baseline mayoritario, sí se detectó diferencia en esta muestra (Regresión Logística: p=0.0000076, LinearSVC: p=0.0000153). La comparación retrospectiva entre la política A de revisión total y la política B con umbral produjo p=0.0078125 al contrastar la corrección de las decisiones binarias frente a las etiquetas. Este último resultado no equivale a un A/B real ni prueba un efecto causal. La significancia no corrige el tamaño pequeño ni el origen sintético de los datos.

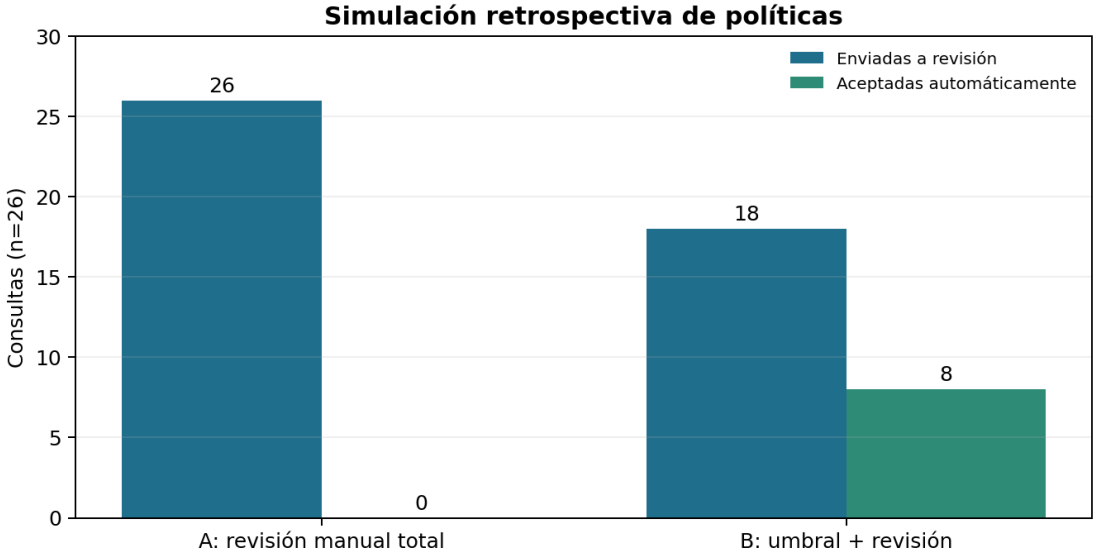


Figura 5. Simulación retrospectiva entre revisión manual total y política de umbral.

Política A: 26 de 26 consultas a revisión. Política B: ocho aceptadas como INDIVIDUAL y 18 a revisión. La reducción observada de casos enviados a revisión es 30.77 %, con cero falsas aceptaciones en esta prueba. Es una simulación retrospectiva pareada: no hubo usuarios reales, asignación aleatoria ni tiempos de servicio medidos. No se calcula ahorro financiero ni se atribuye causalidad.

7. Implicaciones operativas y decisión

Regresión Logística es el candidato experimental preferido por el mejor F1 macro, mejor estabilidad histórica en validación cruzada y cero falsas elegibilidades observadas en prueba. LinearSVC presenta menor latencia en esta ejecución, pero cometió una falsa elegibilidad. La evidencia no justifica desplegar un clasificador como control único.

Acciones recomendadas

- Mantener una puerta de control determinista: validar folio individual, estatus de asignación, tipo de pago y fuente maestra autorizada.
- Aplicar abstención y revisión humana para solicitudes ambiguas, múltiples folios o puntajes insuficientes.
- Ampliar datos AMBIGUA y FUERA_ALCANCE con textos nuevos, doble revisión de etiquetas y una prueba independiente congelada.
- Monitorear falsas elegibilidades, cobertura automática, tasa de abstención, latencia y deriva de vocabulario.
- Versionar datos, código, umbral y modelo, registrar hashes y definir una ruta de reversión auditada.

8.- Conclusión

El resultado de Regresión Logística es sólido dentro de la muestra analizada, pero 26 casos de prueba y dos ejemplos AMBIGUA no son base suficiente para afirmar seguridad productiva. La política de umbral reduce el error observado a cero a cambio de una cobertura automática de 30.77 %. La siguiente decisión razonable es ampliar la evaluación con consultas independientes, estimar el costo real de revisión y conservar la supervisión humana y las reglas deterministas.

Referencias Bibliográficas

Universidad Tecmilenio. (2026). Gestión de proyectos de inteligencia artificial [Curso en línea].
https://cursos.tecmilenio.mx/courses/252871

Google. (s. f.). Gemini: Tu asistente de IA de Google.
https://gemini.google/mx/about/

OpenAI. (s. f.). ChatGPT.
https://chatgpt.com/es-419/

CHATBOT CIMA. (2026). Dataset sintético y resultados de la Actividad 5.
https://github.com/alfredosalazar-ai/deep-learning-experiments/tree/main/Actividad5

Scikit-learn. (s. f.). Model evaluation: quantifying the quality of predictions.
https://scikit-learn.org/stable/modules/model_evaluation.html

Scikit-learn. (s. f.). roc_curve.
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html

Scikit-learn. (s. f.). roc_auc_score.
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html

Scikit-learn. (s. f.). cross_val_predict.
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_predict.html

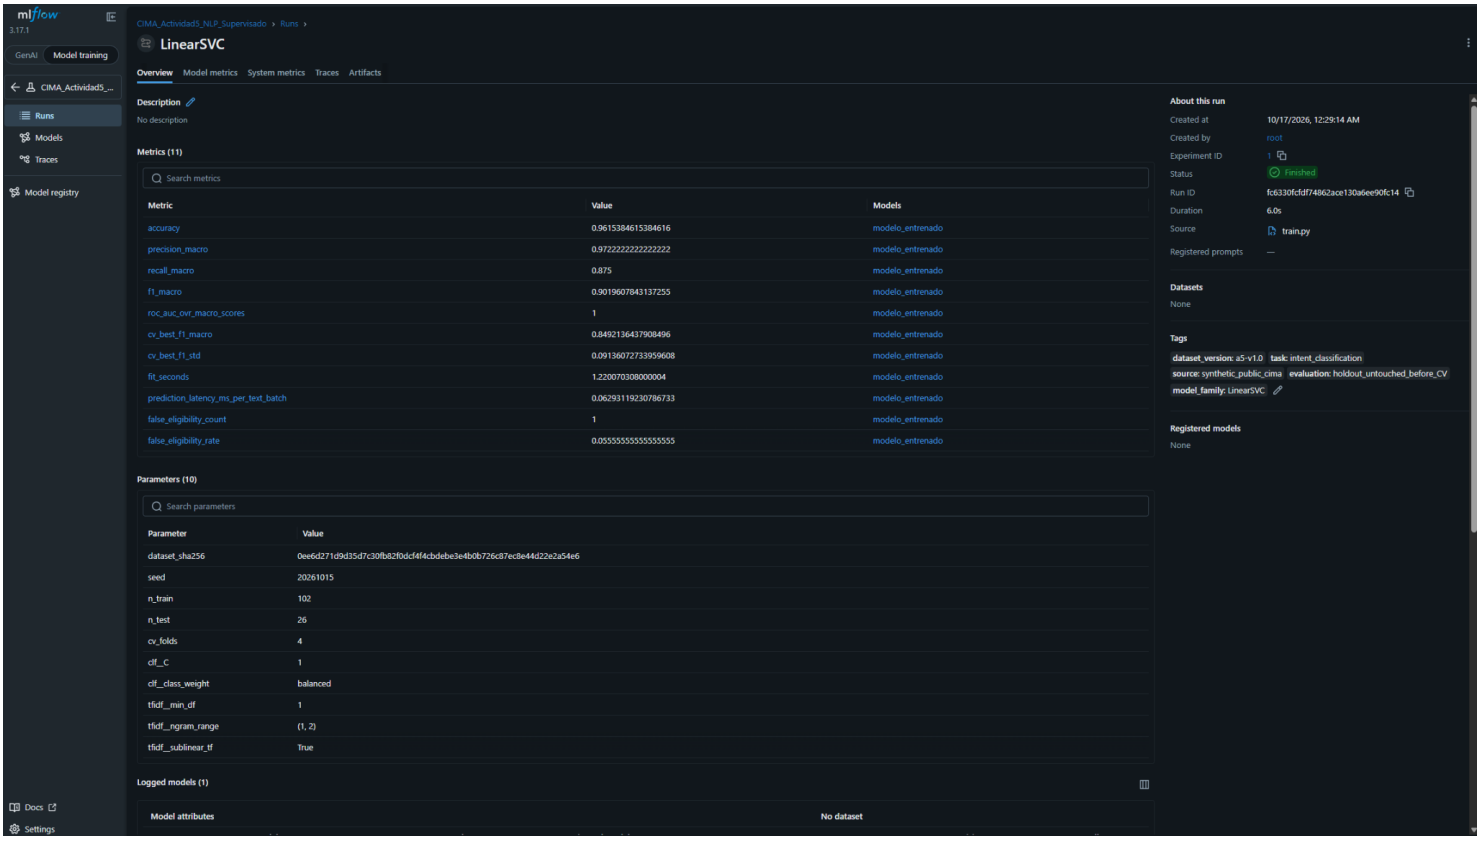
SciPy. (s. f.). scipy.stats.binomtest.
https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.binomtest.html

Nota: las métricas, matrices y parámetros de este informe se extrajeron de los archivos de salida proporcionados. No se realizó un nuevo entrenamiento ni se infieren resultados externos.

Anexo A. Evidencias de MLflow

Las siguientes capturas documentan la visualización de las ejecuciones originales en MLflow 3.17.1, utilizando la base SQLite recuperada y los artefactos restaurados en el entorno temporal de Google Colab. Se conservaron los mismos identificadores de ejecución, no se realizaron nuevos entrenamientos para obtener estas evidencias.
Regresión logística registró accuracy y F1 macro de 1.0000, mientras que LinearSVC obtuvo accuracy de 0.9615 y F1 macro de 0.9020. Estos resultados corresponden a 26 consultas sintéticas de prueba y no demuestran desempeño productivo.

A1. LinearSVC — parámetros, métricas y estado de la ejecución



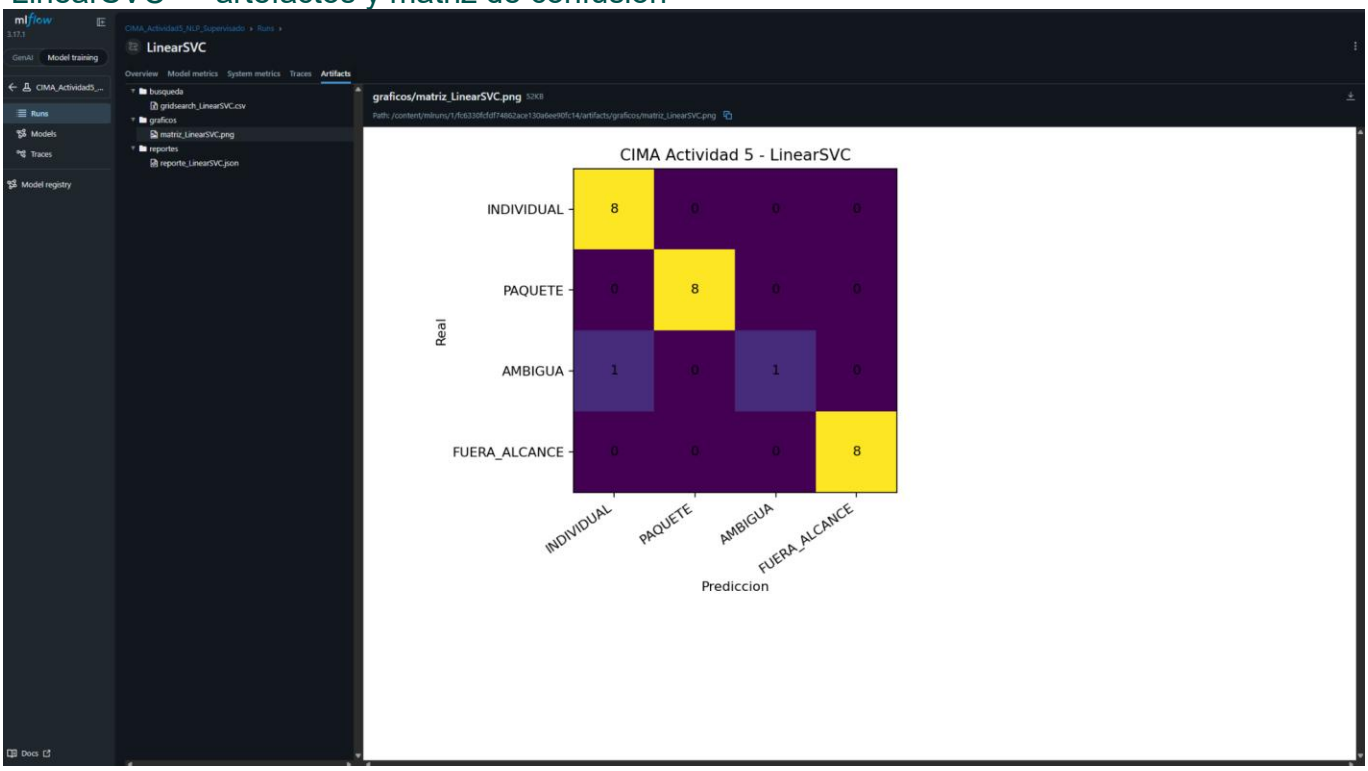
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A2. LinearSVC — visualización de métricas en MLflow



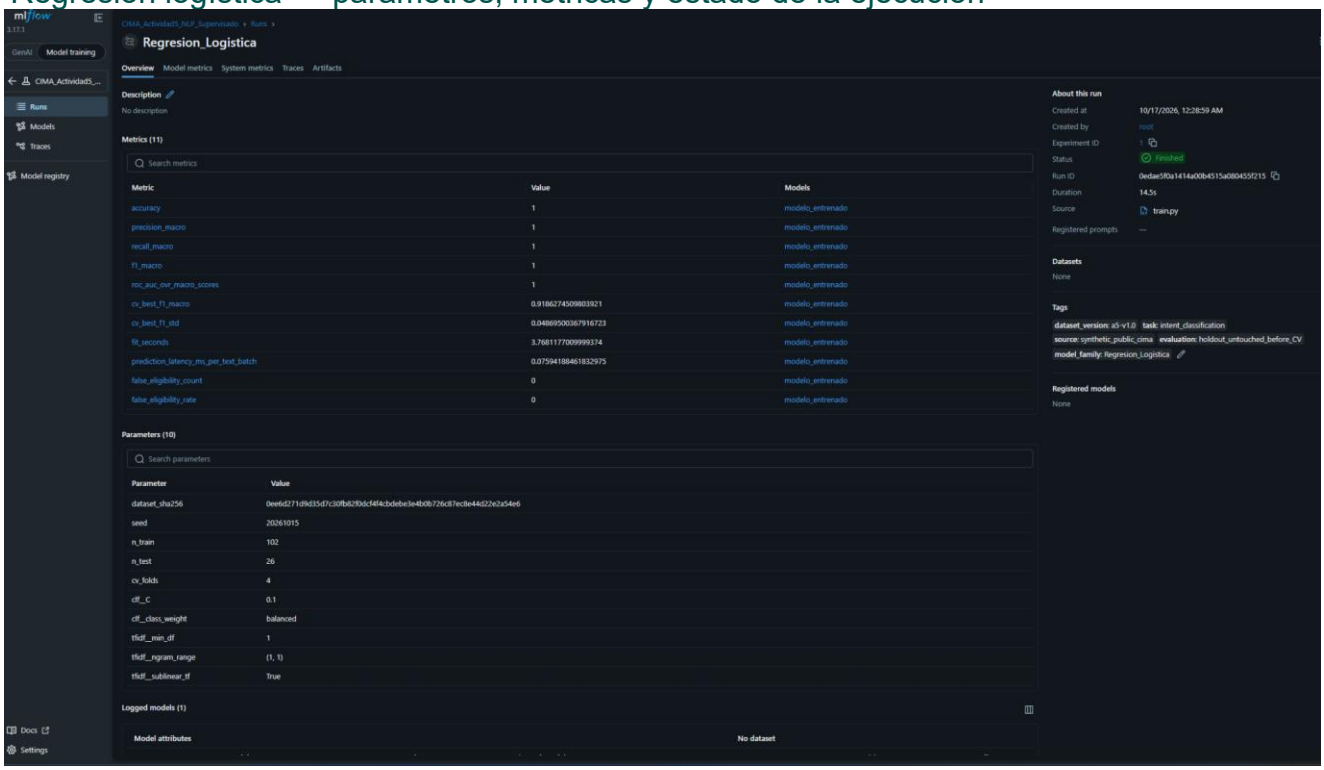
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

3. LinearSVC — artefactos y matriz de confusión



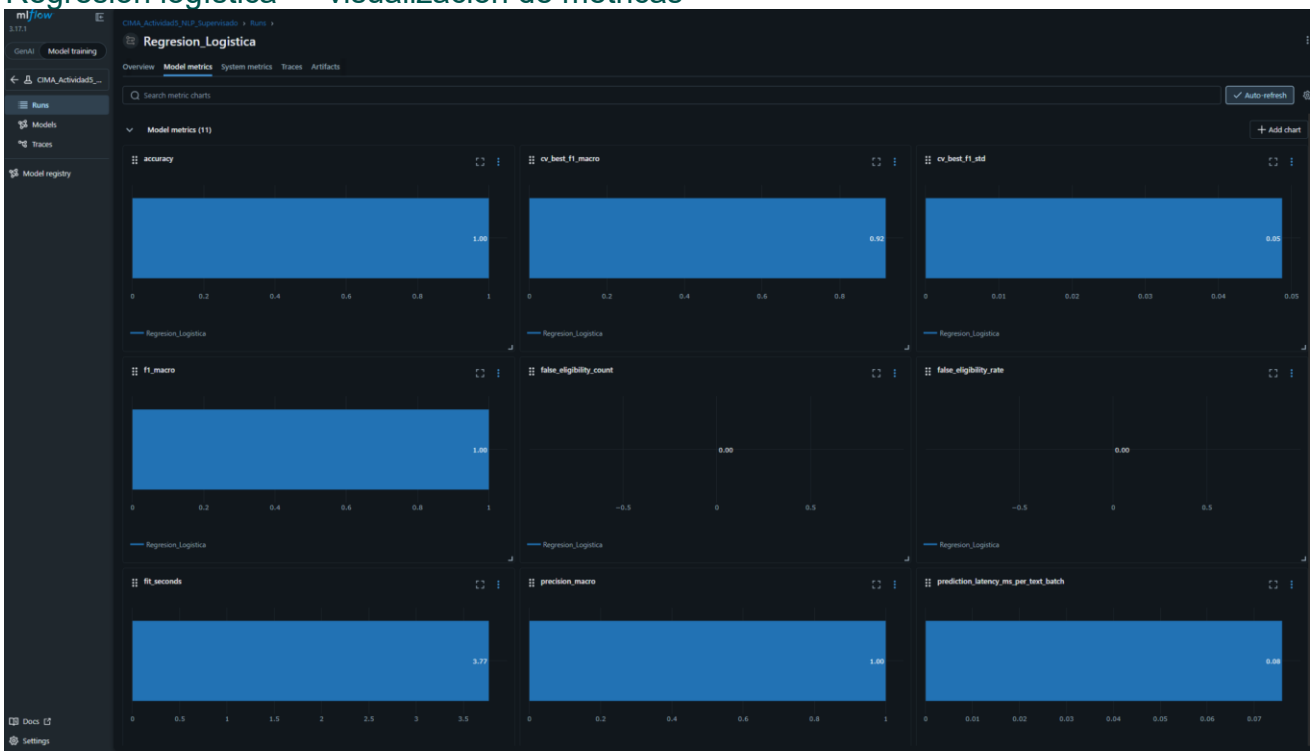
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A4. Regresión logística — parámetros, métricas y estado de la ejecución



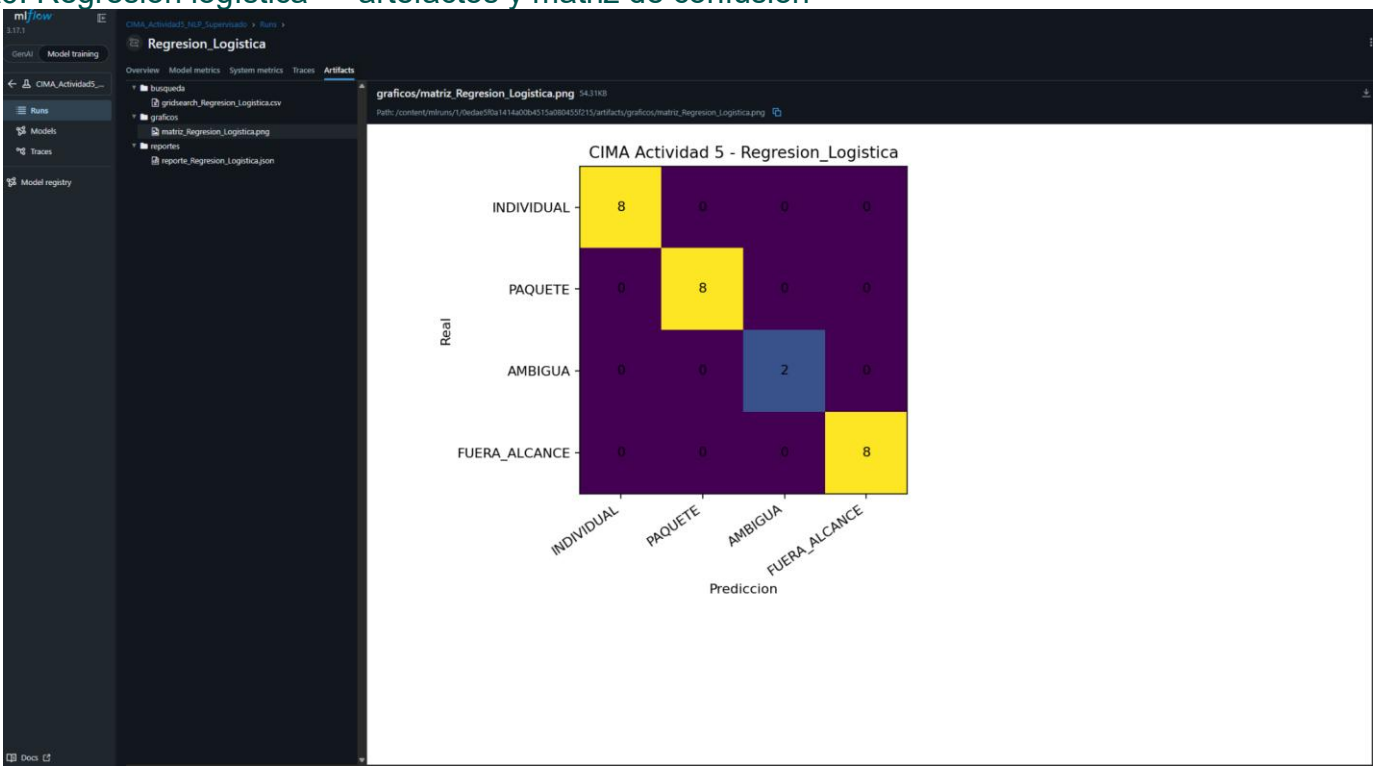
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A5. Regresión logística — visualización de métricas



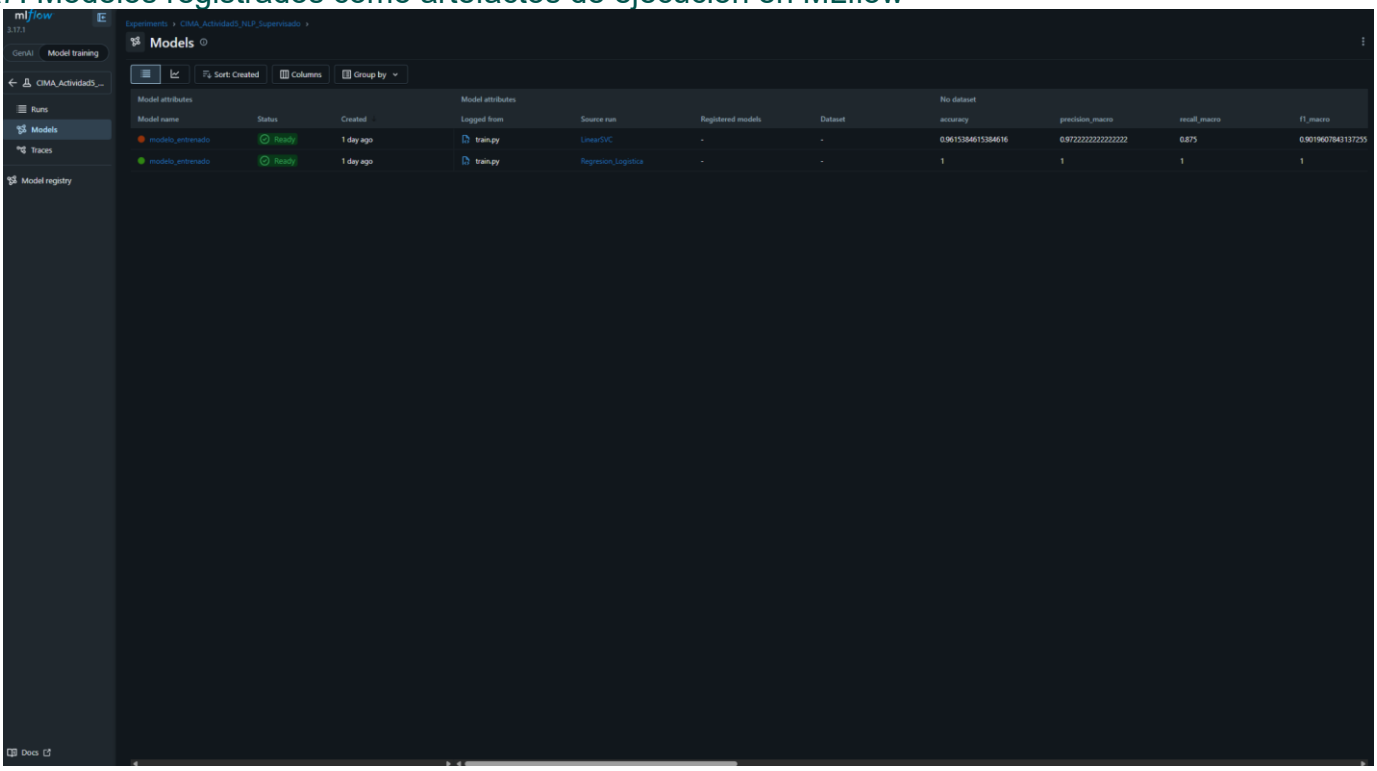
Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A6. Regresión logística — artefactos y matriz de confusión



Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.

A7. Modelos registrados como artefactos de ejecución en MLflow



Fuente: captura del panel MLflow 3.17.1, experimento CIMA_Actividad5_NLP_Supervisado.