REDISEÑO Y GOBERNANZA

Escalabilidad, FinOps y gobernanza responsable de CHATBOT CIMA

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	*Actividad 9*
Alumno(a):	*Alfredo Salazar Ruiz*
Matrícula:	*AL03069191*
Docente:	*Luis Ariel Vázquez Piña*
Fecha de entrega:	*22 / 11 / 2026*

Declaración de Uso de Inteligencia Artificial

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	■ Sí ☐ No	Apoyo en el análisis y entregables de la tarea. Mejora de párrafos, ortografía, ideas claras y contexto de este ensayo.
Claude (Anthropic)	☐ Sí ■ No	
Gemini (Google)	■ Sí ☐ No	Uso de Gemini para verificar el cumplimiento de la rúbrica.
Copilot (Microsoft)	☐ Sí ■ No	
Otra ():	☐ Sí ■ No	

Desarrollo de Contenido

Instrucciones

1.- Un reporte técnico que incluya.

- *Análisis de la arquitectura actual.*
- *Propuesta de rediseño para escalabilidad y optimización de costos.*
- *Evaluación de métricas de desempeño y costo.*
- *Auditoría ética, técnica y legal.*
- *Plan de escalamiento responsable.*

2.- El anexo técnico que incluya.

- *Tablas comparativas de costos.*
- *Métricas de desempeño (latencia, throughput y uso de recursos).*
- *Evaluación de fairness y sesgos.*

4.- Un diagrama de arquitectura

- *Representación del sistema actual y del sistema propuesto.*

ENTREGABLES

- *Reporte técnico en formato Word o PDF.*
- *Anexo técnico en formato XLS o PDF.*
- *Diagrama de arquitectura en formato imagen o PDF.*

Caso de estudio: Consultor Inteligente de Movimientos a Adjudicados (CIMA)

Repositorio: https://github.com/alfredosalazar-ai/deep-learning-experiments

Principio rector: el desempeño técnico y el control de costos no pueden justificar la automatización de una decisión financiera sin evidencia independiente, controles deterministas y autorización institucional.

Resumen ejecutivo

CHATBOT CIMA evolucionó desde la comparación de modelos NLP hasta un prototipo funcional de clasificación de consultas, desplegado mediante FastAPI y Docker en Render, con validaciones mediante GitHub Actions y un laboratorio de observabilidad offline. La Actividad 9 utiliza esa base para evaluar cómo escalar responsablemente el servicio sin confundir una demostración académica con una implantación bancaria.

El análisis identifica tres restricciones prioritarias: capacidad y disponibilidad de una instancia gratuita; falta de validación robusta de la calidad del clasificador ante nuevas consultas; y ausencia de controles de identidad, integración autorizada y auditoría para tratar datos reales. La recomendación es un crecimiento escalonado, condicionado a evidencia de rendimiento, métricas de riesgo y gobierno corporativo.

Se presentan escenarios de cómputo con precios públicos de Render, un modelo editable de costo por mil consultas, dos diagramas de arquitectura, matriz de riesgos, diseño de evaluación de fairness y una hoja de ruta con criterios de salida medibles. Los cálculos de demanda son hipótesis de capacidad; no sustituyen una prueba de carga ni una cotización.

1.- Introducción y antecedentes

CIMA (Consultor Inteligente de Movimientos a Adjudicados) busca orientar consultas relacionadas con movimientos y pagos CIE, principalmente por folio individual. Su alcance académico actual es clasificar la intención, no consultar ni certificar movimientos bancarios. Las categorías son INDIVIDUAL, PAQUETE, AMBIGUA y FUERA_ALCANCE.

En Actividad 4 se compararon clasificadores NLP; en Actividad 5 se trabajó con datos sintéticos y modelos supervisados; en Actividad 6 se validaron métricas, umbrales y decisiones. En Fase II se desplegó FastAPI con Regresión Logística y TF-IDF, y en Actividad 8 se añadieron simulaciones de incidentes, SLO, alertas, runbooks y cinco ejecuciones registradas en MLflow. No se ejecutó una integración productiva a Nueva CIE 2.1.

2.- Objetivo y método

Objetivo: proponer un rediseño técnicamente viable y financieramente medible que permita ampliar capacidad y disponibilidad sin elevar el riesgo de falsas elegibilidades, pérdida de trazabilidad o exposición de información. La evaluación sigue cuatro dimensiones: arquitectura, FinOps, auditoría responsable y plan de escalamiento.

Método: revisión de evidencias académicas proporcionadas y resultados documentados del proyecto; consulta de fuentes públicas de Render, FinOps Foundation, NIST, ISO y legislación mexicana; modelación de escenarios; análisis de amenazas y controles. Se señalan como NO MEDIDOS los indicadores sin ensayos o registros independientes.

3.- Arquitectura actual y línea base

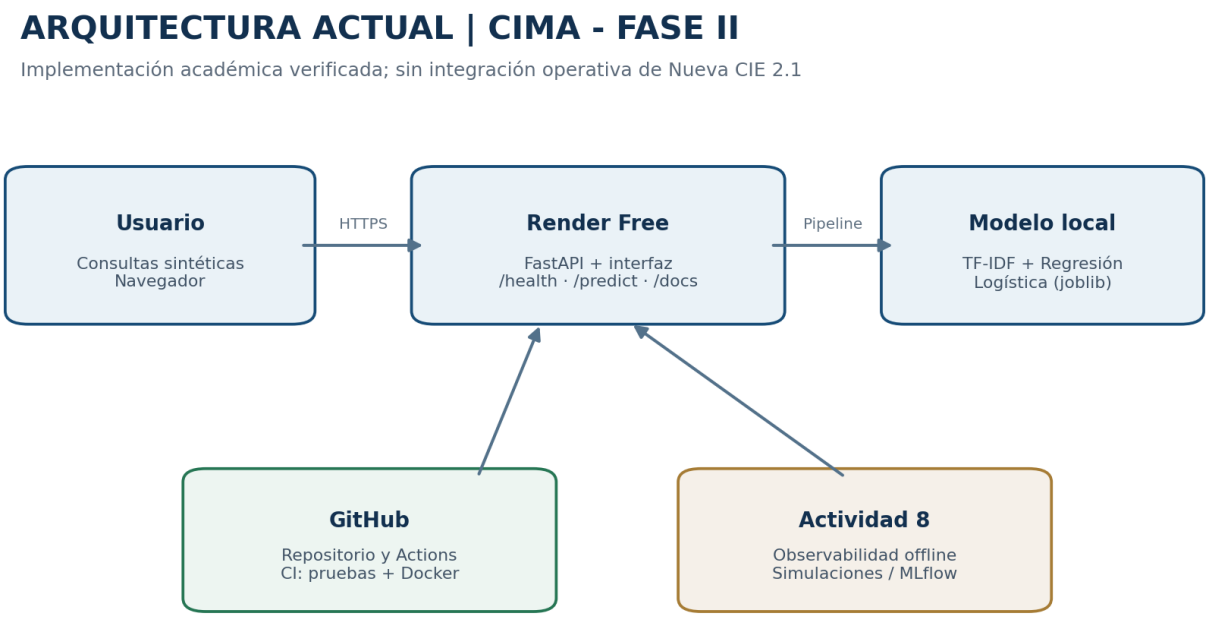


Figura 1. Arquitectura académica actual (representación del diseño documentado).

Componente	Estado verificado	Limitación de escalamiento
FastAPI /predict y /health	API publicada; respuesta HTTP 200 y carga de modelo	Instancia única y arranque en frío
TF-IDF + Regresión Logística	Artefacto joblib de Actividad 5; evaluación A6	Prueba reservada de 26 consultas
Umbral 0.276334	Política conservadora, revisión humana en ejemplos	Cobertura observada en pruebas web: 0/4
Docker + GitHub Actions	Compilación y pruebas remotas exitosas	No prueba multiinstancia ni carga
Actividad 8 / MLflow	Simulaciones offline y cinco runs registrados	No monitoreo continuo ni telemetría de producción

Las pruebas funcionales de Fase II identificaron errores de intención: una solicitud individual extensa resultó AMBIGUA y una solicitud turística fue AMBIGUA en vez de FUERA_ALCANCE. La ausencia de aceptación automática en esas consultas muestra un control conservador; no demuestra sensibilidad o generalización suficiente para operar sin supervisión. El AUC=1.0 de una prueba reservada de 26 casos tiene incertidumbre considerable.

4.- Diagnóstico de escalabilidad

4.1 Escalabilidad vertical frente a horizontal

Vertical: ampliar vCPU y memoria dentro de una instancia, conservando aplicación y despliegue. Es la transición menos compleja para cargas modestas y un modelo pequeño. Horizontal: ejecutar réplicas idénticas sin estado detrás de distribución HTTP, aislando la inferencia del manejo de sesiones, y agregando controles de concurrencia y despliegue gradual.

Render Free dispone de una sola instancia, se suspende tras periodos de inactividad y no permite escalamiento horizontal; por tanto, no ofrece continuidad suficiente para un SLA exigente. La escala horizontal

propuesta depende del plan, región, capacidades comerciales y pruebas de compatibilidad, y no está implementada actualmente. [1, 2]

4.2 Cuellos de botella y validaciones pendientes

- *Arranque en frío: separar latencia de activación de instancia y latencia de inferencia con servidor activo.*
- *Concurrencia: medir throughput sostenido, P50/P95/P99, CPU, RSS, cola y errores con tráfico sintético controlado.*
- *Trabajo sin estado: evitar persistencia local del contenedor; centralizar solo eventos mínimos si el gobierno lo autoriza.*
- *Integridad de decisiones: separar clase predictiva de autorización determinista; los casos incompletos o fuera del alcance siempre escalan.*

5. Rediseño arquitectónico



Figura 2. Arquitectura objetivo condicionada a aprobaciones; componentes no desplegados.

El rediseño conserva FastAPI y el modelo validado como componente intercambiable. Agrega capa de entrada con autenticación y controles de tasa, servicio de inferencia replicable y sin estado, motor determinista de política, revisión humana y observabilidad. El acceso a Nueva CIE 2.1 solo se considera como etapa ulterior, tras aprobación de propietarios de datos, seguridad y arquitectura. No se propone incluir un agente autónomo en el circuito de aprobación de movimientos.

5.1 Condiciones para aceptar escalamientos

- *Corroborar igualdad de predicciones entre modelo fuente y contenedor para un lote etiquetado congelado.*
- *Ejecutar pruebas de carga controladas por niveles y documentar P95 caliente, throughput, CPU, RAM, errores y consumo.*
- *Comparar una instancia mayor con dos réplicas para observar costo, rendimiento y continuidad; no asumir que más réplicas mejora linealmente.*
- *Exigir pruebas de autorización, segregación de roles, protección de datos y trazabilidad previa a fuentes bancarias.*
- *Promover versiones solo tras aprobación formal y mantener rollback probado.*

6. Evaluación FinOps y optimización de costos

Se aplican las fases Inform–Optimize–Operate de FinOps Foundation: identificar drivers, comparar alternativas y operar con presupuestos y métricas unitarias. Los importes son precios públicos de referencia en USD por mes; no constituyen factura, precio contractual ni TCO completo. [1, 3].

Configuración teórica	CPU / RAM	Costo fijo USD/mes	Lectura
Render Free	0.1 vCPU / 512 MB	$0	Pruebas; suspensión y sin SLA productivo
Starter x1	0.5 vCPU / 512 MB	$7	Menor costo, punto único de falla
Standard x1	1 vCPU / 2 GB	$25	Mejora vertical inicial
Standard x2	2 × (1 vCPU / 2 GB)	$50	Redundancia/capacidad, si plan disponible
Pro x1	2 vCPU / 4 GB	$85	Vertical mayor, sin redundancia por sí misma
Standard x3	3 × (1 vCPU / 2 GB)	$75	Hipótesis para más concurrencia

Para comparar configuraciones se propone: capacidad teórica mensual = (réplicas × vCPU × 730 h × 3,600 s/h × utilización objetivo) / segundos CPU por solicitud. El anexo utiliza 0.08 s CPU/solicitud y 55 % de utilización, ambos supuestos que deben calibrarse. El costo fijo por 1,000 solicitudes es tarifa mensual / volumen × 1,000. No se infiere rendimiento real a partir de esta ecuación.

La operación deberá incorporar costo por 1,000 consultas válidas, costo por consulta aceptada con control de calidad, % de presupuesto consumido y P95 por configuración. Como medidas preventivas: control de solicitudes, límites de concurrencia, elección de instancia basada en carga, retención acotada de logs, alertas presupuestales y revisión mensual de costos. Los gastos de almacenamiento, observabilidad adicional, red e intervención humana no están cuantificados en el costo fijo.

7.- Gobierno de IA: auditoría ética, técnica y legal

7.1 Riesgos identificados

Riesgo	Severidad	Control propuesto
Falsa aceptación de consulta como elegible	Crítica	Abstención, reglas deterministas, revisión y prueba independiente
Clasificación errónea de FUERA_ALCANCE	Alta	Negativos difíciles y rechazo de ruido no semántico

Sesgo por escenarios sintéticos repetitivos	Alta	Lotes externos, subtipos, intervalos de confianza
Exposición de datos bancarios	Crítica	RBAC, minimización, cifrado, segregación y no usar servicio público
Trazabilidad y cambios no autorizados	Alta	Firmas/hashes, aprobación de modelo y registros de decisiones
Dependencia de Free / suspensión	Alta	Nivel pagado sujeto a SLO y estrategia de continuidad

7.2 Fairness, sesgos y representatividad

Para CIMA, la auditoría debe evaluar igualdad de trato funcional entre tipos de consulta y expresiones, sin inventar atributos sensibles no disponibles. Los cortes propuestos son: individual directa/indirecta; paquete con múltiples referencias; ambigua sin folio; fuera de alcance por otro tema y por ruido textual. Sobre un conjunto etiquetado nuevo, comparar recall, tasa de falsas elegibilidades y cobertura automática, con intervalos de confianza por corte. No es legítimo afirmar paridad demográfica ni absence de sesgo protegido con los datos actuales.

La evaluación cuantitativa de fairness está PENDIENTE: la información sintética disponible no incluye variables de grupos protegidos, ni un diseño de medición apropiado. La ausencia de datos sensibles es una decisión de minimización, pero requiere declarar la limitación y definir un protocolo aprobado antes de una eventual evaluación formal de equidad para población real.

7.3 Marco normativo y responsabilidades

ISO/IEC 42001:2023 orienta el sistema de gestión de IA y NIST AI RMF estructura gobernar, mapear, medir y gestionar riesgos. Constituyen marcos de referencia, no certificación conseguida. La Ley Federal de Protección de Datos Personales en Posesión de los Particulares publicada el 20 de marzo de 2025 es referencia para tratamiento de datos en México; su aplicabilidad específica, bases jurídicas, transferencias y obligaciones deben revisarse con Jurídico y Privacidad antes de integrar datos reales. [4, 5, 6]

Control	Responsable propuesto	Evidencia exigida
Inventario/versionado de datasets y modelos	Ciencia de Datos	Ficha dataset/model card; hash; versión
Validación independiente y umbrales	Riesgos / Validación de modelos	Matriz, IC, tasas por clase y slices
Acceso y privacidad	Seguridad / Privacidad	Evaluación de impacto, RBAC, pruebas
Ejecución y recuperación	SRE / Operaciones	SLO, runbooks, incidentes, rollback
Costos y decisiones de escala	FinOps / Arquitectura	Comparativo por volumen y autorización
Aceptación de puesta en marcha	Dueño de negocio / Comité	Acta de aprobación y límites de uso

8.- Plan de escalamiento responsable

Etapa	Acción y plazo indicativo	Puerta de control
0 · Cierre de diagnóstico	Semanas 1–2: inventario, baseline, clasificación datos, costos	Evidencias y riesgos aprobados
1 · Calidad / seguridad	Semanas 3–5: >200 ejemplos independientes, slices, RBAC diseño	Resultados por clase + IC; no fuga de datos
2 · Carga y FinOps	Semanas 6–7: comparativa Starter/Standard y N=2	P95, throughput, RSS, USD/1k medidos
3 · Piloto no productivo	Semanas 8–9: hardening, logs mínimos, canary/rollback	Aprobación técnica, seguridad y privacidad
4 · Evaluación institucional	Posterior: consulta a fuente autorizada y gobierno	Aprobaciones formales; no automatizar pagos

Las semanas describen una secuencia prospectiva, no un cronograma aprobado. Criterios mínimos propuestos: SLA definido contractualmente antes de comprometer disponibilidad; P95 caliente ≤2 s en la carga acordada; error HTTP 5xx ≤1 % en ventana representativa; cero falsas elegibilidades observadas con límite superior del IC expresamente reportado; cero secretos o datos reales en repositorio público; trazabilidad íntegra de versión y decisión; presupuesto aprobado. Si no se cumple una puerta, no se promueve a la siguiente etapa.

9.- Evaluación crítica y decisiones

La alternativa de menor costo no es necesariamente la que minimiza el costo operativo: los arranques en frío y la dependencia de una sola instancia pueden perjudicar la experiencia. De igual forma, multiplicar instancias antes de mejorar la calidad de clasificación aumentaría el costo de una solución de utilidad todavía no probada. Se prioriza calidad y control antes de escalar, luego vertical para volumen moderado y horizontal solo cuando la concurrencia y disponibilidad lo justifiquen.

No se recomienda reentrenar ni promover automáticamente por una alerta de drift. Un evento debe activar diagnóstico, comparación con referencia, validación supervisada y decisión humana. El módulo de observabilidad de Actividad 8 es una evidencia de diseño de control en laboratorio y no equivale a monitoreo bancario operativo.

10.- Conclusiones

La arquitectura de CIMA es suficiente como demostrador académico: entrega una API funcional, un pipeline ligero y automatización de pruebas. El salto hacia un uso más intensivo exige medir capacidad real, tratar explícitamente la incertidumbre del clasificador y gobernar los datos y cambios. El rediseño propuesto proporciona una ruta razonable sin comprometer una migración inmediata.

Mi recomendación es mantener el despliegue actual sin alteraciones durante esta actividad, publicar los resultados de diseño y el anexo de escenarios en GitHub, y reservar las decisiones de inversión para después de obtener benchmarks e indicadores de riesgo independientes. La escalabilidad técnica solo genera valor si está acompañada de integridad de la información, trazabilidad y control de decisiones.

Referencias Bibliográficas

Universidad Tecmilenio. (2026). Gestión de proyectos de inteligencia artificial [Curso en línea].
https://cursos.tecmilenio.mx/courses/252871

Google. (s. f.). Gemini: Tu asistente de IA de Google.
https://gemini.google/mx/about/

OpenAI. (s. f.). ChatGPT.
https://chatgpt.com/es-419/

CIMA. (2026). Dataset sintético, scripts y resultados de la Actividad 5.
https://github.com/alfredosalazar-ai/deep-learning-experiments

Render. Pricing.
https://render.com/pricing

Render. Free services & Compute plans.
https://render.com/docs/free
https://render.com/docs/compute-plans

FinOps Foundation. FinOps Framework - Inform, Optimize, Operate.
https://www.finops.org/framework/phases

NIST. AI Risk Management Framework (AI RMF 1.0).
https://www.nist.gov/itl/ai-risk-management-framework

ISO. ISO/IEC 42001:2023, AI management systems.
https://www.iso.org/standard/42001

Orden Jurídico Nacional. LFPDPPP (texto publicado DOF 20-03-2025).
https://www.ordenjuridico.gob.mx/Documentos/Federal/html/wo125102.html

Alfredo Salazar. Repositorio académico deep-learning-experiments: FaseII, Actividad5, Actividad6 y Actividad8.
https://github.com/alfredosalazar-ai/deep-learning-experiments
(evidencias previas del proyecto).

Anexo A. Evidencias de MLflow

El archivo Excel adjunto contiene los supuestos de precios, un modelo reproducible por volumen, métricas observadas/propuestas, diseño de evaluación de fairness y controles. Es intencional que existan campos vacíos donde no se dispone de datos de rendimiento o sesgo empírico. Los diagramas PNG constituyen el componente visual.